

### Lista de Exercícios 3.1

GUSTAVO L. GILARDONI

Os exercícios numerados em verde são optativos.

1. Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição de Poisson com média  $\theta$ , e considere a priori que  $\theta$  tem uma distribuição Gama com parâmetros  $\alpha$  e  $\beta$  (isto é com média  $\alpha\beta^{-1}$  e variância  $\alpha\beta^{-2}$ ). **(i)** Ache a distribuição a posteriori de  $\theta$  e a sua média e variância. **(ii)** Mostre que é possível expressar a esperança a posteriori de  $\theta$  da forma  $w\bar{x} + (1-w)\alpha\beta^{-1}$ , e interprete este resultado. **(iii)** O que acontece na parte **(ii)** quando  $\beta$  é grande com  $\alpha\beta^{-1}$  fixo? Interprete! **(iv)** Mostre que existe um número  $c$  tal que a variância a posteriori é maior do que a variância a priori sempre que  $\bar{x} > c$ , ache  $c$  e interprete este resultado.
2. Considere a seguinte generalização do Exercício 1. Sejam  $y_1, y_2, \dots, y_n$  observações independentes com  $y_i|\theta \sim \text{Poisson}(\theta x_i)$ , onde as exposições  $x_i$  são fixas (não aleatórias). A taxa  $\theta$  segue a priori uma distribuição Gama( $\alpha, \beta$ ). **(i)** Ache a distribuição a posteriori de  $\theta$  e a sua média e variância. **(ii)** Mostre que é possível expressar a esperança a posteriori de  $\theta$  da forma  $(1-w)E(\theta) + w\hat{\theta}$ , onde  $E(\theta)$  e  $\hat{\theta}$  são respectivamente a esperança a priori e a estimativa máximo verossímil de  $\theta$ , e interprete este resultado. **(iii)** O que acontece na parte **(ii)** quando  $\beta$  é grande com  $\alpha\beta^{-1}$  fixo? Interprete!
3. Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição de Poisson com média  $\theta$ , e considere a priori que  $\theta$  tem uma distribuição Gama com parâmetros  $\alpha = 1$  e  $\beta = 1$ . Ache:  
**(a)** a estimativa bayesiana de  $\theta$  no caso de perda quadrática **(b)** o limite do estimativa bayesiana sob perda zero-um quando  $\epsilon \rightarrow 0$ .  
Para o caso  $n = 10$  e  $\bar{x} = 1.55$ , ache:  
**(c)** a estimativa bayesiana sob perda absoluta e **(d)** o intervalo HPD para  $\theta$  com nível 95%.
4. No Exercício 3, calcule o estimador bayesiano para  $\eta = P(x_1 = 0 | \theta) = e^{-\theta}$ . Compare esse estimador com o *estimador não-viesado de variância mínima*  $\tilde{\eta} = (1 - 1/n)^{n\bar{x}}$ .
5. Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição Normal com média  $\mu$  e variância  $\phi^{-1}$  conhecida, e considere a distribuição a priori  $\mu \sim N(\mu_0, \tau^{-1})$ . **(i)** Ache a distribuição a posteriori de  $\mu$ . **(ii)** Mostre que é possível expressar a esperança a posteriori de  $\mu$  da forma  $w\bar{x} + (1-w)\mu_0$ , e interprete este resultado. **(iii)** Se  $\bar{x}_m$  é a média de  $m$  observações futuras  $x_{n+1}, \dots, x_{n+m}$ , condicionalmente independentes de  $x_1, \dots, x_n$ , ache a distribuição preditiva  $p(\bar{x}_m | x_1, \dots, x_n)$ . **(iv)** Discuta o que acontece com os resultados anteriores quando a distribuição a priori  $p(\mu) \propto 1$  (i.e. o caso limite quando  $\tau \rightarrow 0$ ).
6. Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição Normal com média  $\mu$  e variância  $\phi^{-1}$  conhecida, e considere a distribuição a priori  $\mu \sim N(\mu_0, \tau^{-1})$ .  
**(a):** Ache o estimador bayesiano de  $\mu$  no caso de (i) perda quadrática ( $L(\hat{\mu}, \mu) = (\hat{\mu} - \mu)^2$ ), (ii) perda absoluta ( $L(\hat{\mu}, \mu) = |\hat{\mu} - \mu|$ ) e (iii) perda zero-um ( $L(\hat{\mu}, \mu) = I(|\hat{\mu} - \mu| \geq \epsilon)$ ).  
**(b):** Ache o intervalo HPD para  $\mu$  com nível  $100(1 - \alpha)\%$ .
7. Seja  $y_1, y_2, \dots, y_n$  uma amostra da distribuição Exponencial com risco  $\lambda$  e densidade

$p(y|\lambda) = \lambda e^{-\lambda y}$  ( $y > 0$ ) e considere uma distribuição a priori Gama para  $\lambda$ . **(i)** Ache a distribuição a posteriori de  $\lambda$  e a sua média e variância. **(ii)** Considere  $\eta = E(y|\lambda) = \lambda^{-1}$ . Ache a média e a variância a posteriori de  $\eta$ . **(iii)** Discuta se é possível expressar a esperança a posteriori de  $\lambda$  da forma  $(1 - w)E(\lambda) + w\hat{\lambda}$ , onde  $E(\lambda)$  e  $\hat{\lambda}$  são respectivamente a esperança a priori e a estimativa máximo verossímil de  $\lambda$ , e os pesos  $w$  e  $1 - w$  são independentes da amostra. Repita esse estudo para  $\eta$ . **(iv)** Se  $y_{n+1}$  é uma observação futura condicionalmente independente de  $y_1, \dots, y_n$ , ache a distribuição preditiva  $p(y_{n+1}|y_1, \dots, y_n)$

**8.** Repita o Exercício 7 mas supondo agora que, além das  $n$  observações sem censura, existem  $m$  observações que foram censuradas nos momentos  $c_i$ . Isto é, foram observados os tempos de sobrevivência  $y_1, \dots, y_n$  sem censura e, para  $i = n+1, \dots, n+m$  foi somente observado que  $Y_i > c_i$ . (Pode ser útil revisar o Exercício 2 da lista 1).

**9.** Suponha uma amostra  $x_1, \dots, x_n$  da distribuição Normal com média zero e variância  $\sigma^2 = 1/\tau$ . Considere que a priori a precisão  $\tau$  segue uma distribuição Gama com media  $\alpha/\beta$  e variância  $\alpha/\beta^2$ . **(i)** Ache a distribuição a posteriori de  $\tau$ . **(ii)** Mostre que a esperança a posteriori de  $\sigma^2 = 1/\tau$  pode ser escrita da forma  $wE(\sigma^2) + (1 - w)\hat{\sigma}^2$ , onde  $E(\sigma^2)$  é o valor esperado a priori e  $\hat{\sigma}^2$  é o estimador de máxima verossimilhança. Ache  $w$  e interprete. **(iii)** Se  $x_{n+1}$  é uma observação futura da mesma distribuição normal, condicionalmente independente da amostra original, ache a densidade preditiva  $p(x_{n+1}|x_1, \dots, x_n)$ .

**10.** Seja  $y_1, y_2, \dots, y_n$  uma amostra da distribuição Exponencial com risco  $\lambda$  e densidade  $p(y|\lambda) = \lambda e^{-\lambda y}$  ( $y > 0$ ) e considere uma distribuição a priori Gama( $\alpha = 0.1, \beta = 0.1$ ) para  $\lambda$ . Ache

**(a):** a estimativa bayesiana para  $\lambda$  sob perda quadrática; **(b)** o limite da estimativa bayesiana sob perda zero-um quando  $\epsilon \rightarrow 0$ .

No caso  $n = 10$ ,  $\bar{y} = 2.4$ , ache:

**(c)** a estimativa bayesiana de  $\lambda$  sob perda absoluta e **(d)** o intervalo HPD para  $\lambda$  com nível 95%.

**11.** Repita os cálculos do Exercício 10 mas agora para o estimando  $\mu = E(y_1 | \lambda) = \lambda^{-1}$ .

## Algumas Soluções

1. Denote  $D = \{x_1, \dots, x_n\}$  e  $s = x_1 + \dots + x_n$ . (i)  $\theta|D \sim \text{Gama}(\alpha_*, \beta_*)$  com  $\alpha_* = \alpha + s$  e  $\beta_* = \beta + n$ ;  $E(\theta|D) = \alpha_*/\beta_*$  e  $\text{Var}(\theta|D) = \alpha_*/\beta_*^2$ ; (ii)  $w = n/(\beta + n)$ ; (iv)  $c = (\alpha/\beta)(2 + n/\beta) = (2 + n/\beta)E(\theta)$ .

2. Denote  $D = \{y_1, \dots, y_n\}$ ,  $s_x = x_1 + \dots + x_n$  e  $s_y = y_1 + \dots + y_n$ . Logo a verossimilhança é  $p(D|\theta) \propto e^{-\theta s_x} \theta^{s_y}$  e portanto  $\theta|D \sim \text{Gama}(\alpha_*, \beta_*)$  com  $\alpha_* = \alpha + s_y$  e  $\beta_* = \beta + s_x$ . O resto é semelhante ao exercício 1.

3. Seja  $s = \sum_{i=1}^n x_i$ . Temos a posteriori que  $\theta|D \sim \text{Gama}(\alpha_* = \alpha + s = 1 + s, \beta_* = \beta + n = 1 + n)$ . Logo (a) a estimativa sob PQ é  $E(\theta|D) = \alpha_*/\beta_* = (s + 1)/(n + 1)$ , enquanto (b) o limite da estimativa sob perda zero-um é a moda da distribuição a posteriori, que nesse caso é  $(\alpha_* - 1)/\beta_* = s/(n + 1)$ . Agora, quando  $n = 10$  e  $\bar{x} = 1.55$  temos que  $\alpha_* = 16.50$  e  $\beta_* = 11$ , de forma que a estimativa sob PA é a mediana  $\text{med}(\theta|D) \doteq 1.470$ ; (d) O intervalo HPD de nível 95% é  $0.816 \doteq \theta_I < \theta < \theta_S \doteq 2.237$  e precisa ser calculado numericamente. Seguem dois códigos **R**, o primeiro minimiza diretamente o comprimento do intervalo HPD, enquanto o segundo procura que os extremos do intervalo tenham a mesma densidade a posteriori.

```
conf<-0.95
alfa<-16.5
beta<-11
```

```
# Minimizando o comprimento do intervalo
```

```
comp<-function(a){qgamma(conf+a,alfa,beta)-qgamma(a,alfa,beta)}
ainf<-optimize(f=comp,lower=0,upper=1-conf)$minimum
ainf
theta.i<-qgamma(ainf,alfa,beta)
theta.s<-qgamma(conf+ainf,alfa,beta)
```

```
# igualando a densidade nos dois extremos
```

```
dif<-function(a){dgamma(qgamma(conf+a,alfa,beta),alfa,beta)-
  dgamma(qgamma(a,alfa,beta),alfa,beta)}
ainf<-uniroot(f=dif,lower=0,upper=1-conf)$root
theta.i<-qgamma(ainf,alfa,beta)
theta.s<-qgamma(conf+ainf,alfa,beta)
```

4.  $E(e^{-\theta}|D) = [1 - 1/(\beta + n + 1)]^{\alpha + n\bar{x}}$ .

5. Veja a Seção correspondente das notas de aula.

6. Como a distribuição a posteriori  $\theta|D \sim \text{Normal}(\mu_* = (\lambda\mu_0 + n\tau\bar{y})/(\lambda + n\tau), (\lambda_*)^{-1} = (\lambda + n\tau)^{-1})$  é simétrica com respeito a  $\mu_*$ , segue que (a) o estimador bayesiano com respeito às perdas quadrática, absoluta e zero-um (para qualquer  $\epsilon > 0$ ) é  $\mu_*$  e que (b) o intervalo HPD de nível  $100(1 - \alpha)\%$  é  $\mu_* \pm z_{\alpha/2}(\lambda_*)^{-1/2}$ .

7. Denote  $D = \{y_1, \dots, y_n\}$  e  $s = \sum_{i=1}^n y_i$ . (i)  $\lambda|D \sim \text{Gama}(\alpha_* = \alpha + n, \beta_* = \beta + s)$  de forma que  $E(\lambda|D) = \alpha_*/\beta_*$  e  $\text{Var}(\lambda|D) = \alpha_*/\beta_*^2$ ; (ii) mostre primeiro que, se  $U \sim \text{Gama}(\alpha, \beta)$ , então  $E(U^r) = \Gamma(\alpha + r) \beta^{-r} / \Gamma(\alpha)$  para  $\alpha + r > 0$ . Com isso,  $E(\eta|D) = \beta^*/(\alpha_* - 1)$  para  $n > 1 - \alpha$  e  $\text{Var}(\eta|D) = \beta_*^2 / [(\alpha_* - 1)^2 (\alpha_* - 2)]$  para  $n > 2 - \alpha$ ; (iii) só é possível na parametrização  $\eta = \lambda^{-1}$  e nesse caso  $w = n/(\alpha + n - 1)$ ; (iv)  $p(y_{n+1}|y_1, \dots, y_n) = \alpha_* \beta_*^{\alpha_*} (\beta_* + y_{n+1})^{-\alpha_* - 1}$  para  $y_{n+1} > 0$  (i.é.  $(\beta_* + y_{n+1})|D$  segue uma distribuição de Pareto com parâmetros  $\beta_*$  e  $\alpha_*$ ).

8. Defina nesse caso  $\alpha_* = \alpha + n$  (somente considera as observações não censuradas) e  $\beta_* = \sum_{i=1}^n y_i + \sum_{i=n+1}^{n+m} c_i$  (considera todas as observações). Então  $\lambda|D \sim \text{Gama}(\alpha_* = \alpha + n, \beta_* = \beta + s)$ . O resto é semelhante ao exercício 8.

9. Defina  $D = \{x_1, \dots, x_n\}$  e  $s^2 = \sum_{i=1}^n x_i^2$ . (i)  $\tau|D \sim \text{Gama}(\alpha_* = \alpha + n/2, \beta_* = \beta + s^2/2)$ ; (ii) semelhante aos exercícios 7 e 8; (iii) Defina  $Y_{n+1} = (\alpha_*/\beta_*)^{1/2} X_{n+1}$ . Então  $Y_{n+1}|D$  segue uma distribuição  $t$  de Student com  $(2\alpha_*)$  graus de liberdade.

10. Semelhante ao exercício 3.