

Lista de Exercícios 3.2

GUSTAVO L. GILARDONI

Os exercícios numerados em verde são optativos.

1. Considere o modelo $X \sim \text{Uniforme}(\theta, \theta + 1)$ ($-\infty < \theta < \infty$).
 - (a) Mostre que θ é um parâmetro de localização.
 - (b) Dada a priori não informativa usual para o modelo de localização, $p(\theta) \propto 1$ e uma amostra aleatória X_1, \dots, X_n do modelo acima, discuta a propriedade da distribuição a posteriori.
 - (c) Na situação da parte (b), ache: (i) os estimadores bayesianos sob Perda Quadrática e sob Perda Absoluta; (ii) O intervalo HPD para θ com credibilidade $100(1 - \alpha)$ e (iii) A probabilidade a posteriori do evento $\theta > \theta_0$.
2. Considere o modelo $X \sim \text{Uniforme}(0, \theta)$ ($0 < \theta < \infty$).
 - (a) Mostre que $\sigma = \theta^{-1}$ é um parâmetro de escala.
 - (b) Dada a priori não informativa usual para o modelo de escala, $p(\sigma) \propto \sigma^{-1}$ e uma amostra aleatória X_1, \dots, X_n do modelo acima, discuta a propriedade da distribuição a posteriori.
 - (c) Na situação da parte (b), ache: (i) os estimadores bayesianos sob Perda Quadrática e sob Perda Absoluta; (ii) O intervalo HPD para θ com credibilidade $100(1 - \alpha)$ e (iii) A probabilidade a posteriori do evento $\theta > \theta_0$.
3. Considere o modelo $x_1, \dots, x_n | \theta \sim \text{Ber}(\theta)$.
 - (a) Calcule a priori de Jeffreys e mostre que ela é própria.
 - (b) Considere uma amostra aleatória X_1, \dots, X_n do modelo acima e a priori de Jeffreys. Ache o estimador bayesiano de θ sob Perda Quadrática e explique como achar um intervalo HPD para θ com credibilidade $100(1 - \alpha)$.
4. Suponha o modelo $y \sim \text{NegBin}(k, \theta)$.
 - (a) Ache a distribuição a priori de Jeffreys e discuta a sua propriedade e da correspondente distribuição a posteriori.
 - (b) Compare os resultados acima com os obtidos no Exercício 3 e discuta a seguinte afirmação: *A distribuição a priori de Jeffreys viola o princípio de verossimilhança.*
5. Suponha amostras aleatórias dos seguintes modelos. Em cada caso, calcule a distribuição a priori de Jeffreys e discuta se as distribuições a priori e a posteriori são próprias.
 - (a) Poisson(θ);
 - (b) Exponencial com risco λ ;
 - (c) Multinomial com $k = 3$ e parâmetro $(\theta_1, \theta_2, \theta_3)$;
 - (d) Normal com média μ e precisão τ , as duas desconhecidas.
6. Considere o modelo $x_i | \mu_i, \mu_0, \tau \stackrel{\text{indep}}{\sim} N(\mu_i, 1)$ ($i = 1, \dots, n$) com a priori (imprópria) $p(\mu_1, \dots, \mu_n; \mu_0, \tau) \propto \tau^{-1} \prod_{i=1}^n n(\mu_i | \mu_0, \tau^2)$, onde $n(x | \mu, \sigma^2)$ é a densidade da distribuição Normal com média μ e variância σ^2 . Mostre que a distribuição a posteriori é imprópria quaisquer que sejam as observações x_1, \dots, x_n .

Algumas Soluções

1. **(a)** Para uma única observação temos que $p(x|\theta) = I(\theta < x < \theta + 1) = I(0 < x - \theta < 1)$, isto é, na notação das notas de aula, $f(x) = I(0 < x < 1)$ é a densidade da Uniforme(0,1) [alternativamente, observe que $X \sim \text{Uniforme}(\theta, \theta + 1)$ se, e somente se, $U = X - \theta \sim \text{Uniforme}(0,1)$]. **(b)** Denote por $x_{(1)}$ e $x_{(n)}$ respectivamente o mínimo e o máximo das n observações. A verossimilhança é $p(x_1, \dots, x_n | \theta) = \prod_{i=1}^n I(\theta < x_i < \theta + 1) = I(x_{(n)} - 1 < \theta < x_{(1)})$. Assim, usando a priori $p(\theta) \propto 1$ temos que $p(\theta | x_1, \dots, x_n) \propto I(x_{(n)} - 1 < \theta < x_{(1)})$ e portanto a posteriori θ segue uma distribuição Uniforme($x_{(n)} - 1, x_{(1)}$) (sempre própria). **(c)** **(i)** $\hat{\theta}_{PQ} = \hat{\theta}_{PA} = (x_{(1)} + x_{(n)} - 1)/2$; **(ii)** Na verdade qualquer intervalo com probabilidade a posteriori $(1 - \alpha)$ será HPD, por exemplo o intervalo central com limites $x_{(n)} - 1 + (\alpha/2)(1 - x_{(n)} + x_{(1)})$ e $x_{(1)} - (\alpha/2)(1 - x_{(n)} + x_{(1)})$; **(iii)** Se $x_{(n)} - 1 < \theta_0 < x_{(1)}$ a probabilidade desejada é $(x_{(1)} - \theta_0)/(1 - x_{(n)} + x_{(1)})$.
2. **(a)** Para uma única observação temos que $p(x|\theta) = \theta^{-1}I(0 < x < \theta) = \theta^{-1}I(0 < x/\theta < 1)$, isto é, na notação das notas de aula, $f(x) = I(0 < x < 1)$ é a densidade da Uniforme(0,1) [alternativamente, observe que $X \sim \text{Uniforme}(0, \theta)$ se, e somente se, $U = X/\theta \sim \text{Uniforme}(0,1)$]. **(b)** A densidade $p(\sigma) \propto \sigma^{-1}$ é equivalente a assumir que $p(\theta) \propto [1/(1/\theta)] | -1/\theta^2 | \propto \theta^{-1}$. Logo, a densidade a posteriori seria $p(\theta | x_1, \dots, x_n) \propto \theta^{-1} \theta^{-n} I(\theta > x_{(n)}) \propto \theta^{-(n+1)} I(\theta > x_{(n)})$. Como $\int_{x_{(n)}}^{\infty} \theta^{-(n+1)} d\theta = [n x_{(n)}^n]^{-1} < \infty$ para todo $x_{(n)}$, a densidade é sempre própria (a distribuição a posteriori de θ é dita de Pareto). **(c)** **(i)** $\hat{\theta}_{PQ} = n x_{(n)}/(n - 1)$ (para $n > 1$, se $n = 1$ é infinita), $\hat{\theta}_{PA} = x_{(n)} 2^{1/n}$; **(ii)** Como a densidade é decrescente, o intervalo HPD é $(x_{(n)}, x_{(n)} \alpha^{-1/n})$; **(iii)** $[x_{(n)}/\theta_0]^n$ (para $\theta_0 \geq x_{(n)}$).
3. **(a)** $p_J(\theta) \propto \theta^{-1/2} (1 - \theta)^{-1/2}$ [a distribuição Beta($\alpha = 1/2, \beta = 1/2$), própria]. **(b)** $\theta | x_1, \dots, x_n \sim \text{Beta}(\alpha = s + 1/2, \beta = n - s + 1/2)$, onde $s = \sum_{i=1}^n x_i$; $\hat{\theta}_{PQ} = (s + 1/2)/(n + 1)$; para o intervalo HPD, adapte o algoritmo usado no exercício 4 da Lista 2.
- 4 **(a)** Consideramos $p(y|\theta) = \binom{y+k-1}{y} \theta^y (1 - \theta)^k$ para $y = 0, 1, \dots$; $p_J(\theta) \propto \theta^{-1/2} (1 - \theta)^{-1}$ [isto é, a “distribuição” Beta($1/2, 0$), imprópria]; a distribuição a posteriori seria a Beta($y + 1/2, k$), sempre própria pois obviamente $k > 0$. **(b)** Comparando com o exercício 3, considere o caso $y = s$ e $k = n - s$, de forma que as verossimilhanças são proporcionais; no exercício 3 temos por exemplo $\hat{\theta}_{PQ} = (s + 1/2)/(n + 1)$, enquanto aqui teríamos $\hat{\theta}_{PQ} = (y + 1/2)/(y + k + 1/2) \neq (s + 1/2)/(n + 1)$.
5. **(a)** $p_J(\theta) \propto \theta^{-1/2}$, a “distribuição” Gama($1/2, 0$), imprópria; a posteriori é Gama($s + 1/2, n$), sempre própria. **(b)** $p_J(\lambda) \propto \lambda^{-1}$, a “distribuição” Gama($0, 0$), imprópria; a posteriori é Gama(n, s), sempre própria (pois $n, s > 0$ com probabilidade 1). **(c)** $p_J(\theta_1, \theta_2, \theta_3) \propto \theta_1^{-1/2} \theta_1^{-1/2} \theta_1^{-1/2}$, a distribuição de Dirichlet com parâmetros $\alpha_1 = \alpha_2 = \alpha_3 = 1/2$, própria. **(d)** $p_J(\mu, \tau) \propto \tau^{-1}$, imprópria [parametrizando com o desvio padrão σ , temos $p_J(\mu, \sigma) \propto \sigma^{-1}$]; a posteriori é sempre própria (veja as notas de aula).
6. A forma mais fácil de resolver, assim como a melhor para entender o problema, consiste em integrar os parâmetros μ_1, \dots, μ_n e obter o modelo resultante somente com os parâmetros (μ_0, τ) . Mostre primeiro que $x_i | \mu_0, \tau \stackrel{\text{indep}}{\sim} \text{Normal}(\mu_0, 1 + \tau^2)$. Usando

agora a priori $p(\mu_0, \tau) \propto \tau^{-1}$, a densidade a posteriori seria $p(\mu_0, \tau | x_1, \dots, x_n) \propto \tau^{-1} \prod_{i=1}^n \sqrt{\frac{1}{2\pi(1+\tau^2)}} \exp\{-(x_i - \mu_0)^2 / [2(1+\tau^2)]\} \propto \tau^{-1} [2\pi(1+\tau^2)]^{-n/2} \prod_{i=1}^n \exp\{-(x_i - \mu_0)^2 / [2(1+\tau^2)]\}$. Finalmente, mostre que existe uma constante $c > 0$ tal que $\int_{-\infty}^{\infty} \prod_{i=1}^n \exp\{-(x_i - \mu_0)^2 / [2(1+\tau^2)]\} d\mu_0 > c$, de forma que $\int_0^{\infty} \int_{-\infty}^{\infty} \tau^{-1} [2\pi(1+\tau^2)]^{-n/2} \prod_{i=1}^n \exp\{-(x_i - \mu_0)^2 / [2(1+\tau^2)]\} d\mu_0 d\tau > c \int_0^{\infty} \tau^{-1} [2\pi(1+\tau^2)]^{-n/2} d\tau = \infty$ (o último integrando é da ordem de τ^{-1} perto de $\tau = 0$, portanto a integral é divergente).