

# Bayesiana

## \* Lata 2

1)

- i) Seja :  $H$ : A moeda é honesta;  $P(H) = \frac{1}{2} = 0,5$  ;  
 $H^c$ : A moeda é falsa;  $P(H^c) = 1 - \frac{1}{2} = 0,5$  ;  
 $C$  : O resultado do lançamento é cara;  
 $C^c$  : " " " " " coroa.

Então ;  $P(C|H) = 0,5$ ;  $P(C|H^c) = 1$ . {Pois  $H^c$  tem 2 caras}.

Então ;  $P(C) = P(C|H)P(H) + P(C|H^c)P(H^c)$   
 (Ley da probabilidade total)  
 $= (0,5)(0,5) + 1 \cdot 0,5$   
 $= 0,25$

ii)  $P(H^c|C) = \underbrace{\frac{P(C|H^c)P(H^c)}{P(C)}}_{\substack{= \\ \underbrace{P(C)}}} = \frac{1 \cdot 0,5}{0,25} = \frac{2}{3}$

Teorema de Bayes

- iii) Se  $C$  : O resultado é cara;  $C = C^2 = C$ . Se repete o experimento;  $C \cdot C \cdot C \cdots C = C^n$ . O resultado é cara em  $n$  lançamentos.

Então ;  $P(C^n) = P(C^n|H)P(H) + P(C^n|H^c)P(H^c)$   
 (Ley da prob. total)  
 $= (0,5^n)(0,5) + 1^n \cdot 0,5$   
 $= 0,5^{n+1} + 0,5$ .

(Continuação 1) iii))

Logo, temos que  $P(H^c | C^n) = \underbrace{\frac{P(C^n | H^c) P(H^c)}{P(C^n)}}_{\text{Teorema de Bayes}}$

$$(*) : P(C^n | H^c) = P(C | H^c) = 1$$

Se não há caras em  $H^c$ ;  $(*) = 1 \forall n > 0$ .

$$\frac{1 - 0,5}{0,5^{n+1} + 0,5}$$

$$\lim_{n \rightarrow \infty} \frac{0,5}{0,5^{n+1} + 0,5} = 0$$

Isto é, quanto mais lancarmos a moeda, e mais caras começaremos a obter; Mas o que é a hipótese da moeda de fato ser falsa.

- iv) Seja  $C^1 = \emptyset$  1º lançamento resulta cara;  
 $C^2 = \emptyset$  2º lançamento é cara.

Temos: Em 1) ii), calculamos  $P(H^c | C) = \frac{2}{3} = P(H^c | C^1)$ .  
Então  $P(H | C) = 1 - \frac{2}{3} = \frac{1}{3} = P(H | C^1)$

Pelo Teorema de Bayes,  $P(C^2 | C^1) = P(C^2 | H^c) P(H^c | C^1)$

(onde:  $P(C^2 | H^c) = 1$ ; e  $P(C^2 | H) P(H | C^1)$ ;

$$P(C^2 | H) = \frac{1}{2}, \text{ otherwise.}$$

$$\begin{aligned} \text{Logo, } P(C^2 | C^1) &= 1 \cdot \frac{2}{3} + 0,5 \cdot \frac{1}{3} \\ &= \frac{5}{6}. \end{aligned}$$

v) Se os lançamentos serão independentes  $\Leftrightarrow P(C_j \cap C_k)$

$$= P(C_j) \cdot P(C_k)$$

3

ou,  $P(C^j | C^k) = P(C^j)$ ; O que não faz sentido  
neste caso. Vida que mostramos que  $P(C^2 | C^1) \neq P(C^2)$ .  
Para obter a independência condicional, precisaríamos  
saber se a moeda é honesta ou não.

2)  $y_1, y_2, \dots, y_n \sim \text{Bernoulli}(\theta)$ ,  
 $\theta \sim \text{Uniforme}(0, 1)$

i) Posteriori:  $P(\theta | y_1, y_2, \dots, y_n)$

Seja  $\sum_{i=1}^n y_i = K$  o número de moedas descritas na  
amostra; Então;

$$P(y_1, \dots, y_n | \theta) = \theta^K (1-\theta)^{n-K}$$

E:  $P(\theta) = 1$ . Então; é a verossimilhança  
de uma Bernoulli.

$$P(\theta | y_1, \dots, y_n) \propto \theta^K (1-\theta)^{n-K} \cdot 1$$

Que tem a forma de uma Beta ( $\alpha = K+1$ ,  $\beta = n-K+1$ )

Se a posteriori de  $\theta$  é uma Beta com estes parâmetros, então:

$$E(\theta) = \frac{\alpha}{\alpha+\beta} = \frac{K+1}{(K+1)+(n-K+1)} = \frac{K+1}{n+2}$$

$$\begin{aligned}
 E[\text{variação}] &\Rightarrow \text{Var}(\theta) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} \quad (\text{Def.}) \\
 &= \frac{(K+1)(n-K+1)}{\left[(K+1)+(n-K+1)\right]^2 \left[(K+1)+(n-K+1)+1\right]} \\
 &= \frac{(K+1)(n-K+1)}{(n+2)^2(n+3)}
 \end{aligned}$$

ii) Expressar o exp. de forma  $(1-\omega) E(\theta) + \omega \hat{\theta}$ .

A priori,  $\theta \sim \text{Unif}$ , logo  $E(\theta) = \frac{a+b}{2} = \frac{0+1}{2} = 0,5$ .

E, a estimar  $\hat{\theta}$  para a bernoulli é dado por  $\frac{K}{n}$ , i.e., a razão de sucessos, dividido pelo número de tentativas.

E, a expressão da posterior calculada em i) é  $\frac{a}{a+b} = \frac{K+1}{n+2}$ .

Portanto:

$$\frac{K+1}{n+2} = (1-\omega) E(\theta) + \omega \hat{\theta}$$

$$\frac{K+1}{n+2} = (1-\omega) \underbrace{\frac{1}{2}}_{\text{V.a. da Priori}} + \omega \underbrace{\frac{K}{n}}_{\text{V.a. da M.l.}}$$

V.a. da Priori - V.a. da M.l.

Desta forma, vemos que a expectativa da posterior pode ser escrita como uma nova ponderação dos conhecimentos a priori e a verossimilhança dos dados, e deve ser tal que o aumento da amostra da cerninimangá tem o efeito de prior que é igualitário conforme n aumenta; i.e.; constante - ou  $f(n)$

iii)

Predição:  $E_{\text{Amostra}(K+1, n-K+1)} [\text{Amostra}(y|O)]$

Então,

$$P(y_{n+1} | y_1, \dots, y_n) = \underbrace{\int_0^1 P(y_{n+1} | \theta) P(\theta | y_1, \dots, y_n) d\theta}_{\substack{\text{Amostra} \\ (\text{Bernoulli})}} \underbrace{\theta^K (1-\theta)^{n-K}}_{\substack{\text{Posteriori} \\ (\text{Beta})}}$$

Logo:

$$P(y_{n+1} | y_1, \dots, y_n) \stackrel{(*)}{=} \int_0^1 \theta^{y_{n+1}} (1-\theta)^{n-y_{n+1}} \frac{\theta^K (1-\theta)^{n-K}}{B(K+1, n-K+1)} d\theta$$

$$\stackrel{(*)}{=} \int_0^1 \frac{\theta^{K+1} (1-\theta)^{n-K}}{B(K+1, n-K+1)} d\theta$$

$$= \frac{1}{B(K+1, n-K+1)} \int_0^1 \theta^{K+2} (1-\theta)^{n-K} d\theta = \frac{B(K+2, n-K+1)}{B(K+2, n-K+1)}$$

$$= \frac{\Gamma(K+2) \Gamma(n-K+1)}{\Gamma(K+2+n-K+1)} \frac{\Gamma(K+2) \Gamma(n-K+1)}{\Gamma(n+2)} = \boxed{\frac{n+1}{n+2}}$$

$$\begin{aligned}
 & \text{Se } y_{m+2} = 0; \\
 & P(y_{m+2} = 0 | y_1, \dots, y_n) = \int_0^1 \theta^0 (1-\theta)^{n-m} \frac{\theta^K (1-\theta)^{n-K}}{B(K+1, n-K+2)} d\theta \\
 & = \frac{1}{B(K+1, n-K+2)} \int_0^1 \theta^K (1-\theta)^{n-K+1} d\theta \\
 & = \frac{B(K+1, n-K+2)}{B(K+1, n-K+2)} = \frac{\cancel{\Gamma(K+1)\Gamma(n-K+2)}}{\cancel{\Gamma(n+3)}} \\
 & = \frac{\cancel{\Gamma(n-K+2)\Gamma(n+2)}}{\cancel{\Gamma(n+3)\Gamma(n-K+2)}} = \boxed{\frac{n-K+2}{n+2}}
 \end{aligned}$$

$$4) \text{i) } PQ = \arg \min E[(\theta - PQ)^2 | y_1, \dots, y_n]$$

$$\stackrel{\text{Median}}{\text{posterior}} = \frac{K+1}{n+2}$$

$$\text{ii) Parabola } \theta - 2 = \text{Meda } ; P/n = 1, 2 ; S = \sum_{i=1}^{12} y_i = 9$$

$$\text{Diff. Meda Beta} = \frac{\alpha - 1}{\alpha + \beta - 2}, \alpha, \beta > 1$$

$$\text{Entw} = \frac{9+1-2}{9+1+12-9+1-2} = \frac{9}{12} = 0,75$$

iii) Pórdia alardata - Mediana posterior ( $n=12; S=9$ )

Def Mediana Beta  $\approx \alpha - \frac{1}{3}$

$$\begin{aligned} & \overline{\alpha + \beta - 2/3} \\ & \approx \frac{\overline{\alpha + 1} - \frac{1}{3}}{\underbrace{\overline{\alpha + 1 + 12 - \alpha + 1 - 2/3}}_{14}} = \frac{9,76/3}{13,33} \\ & \approx 0,725 \end{aligned}$$

iv) HPD 99%

Será o intervalo quantílico da posterior, i.e.

no n:  $q\text{beta}(.005, 10, 4)$ ;  $q\text{beta}(.995, 10, 4)$

$$= [0,3793, 0,9429...]$$

8) i)

Prior:  $(p_1, p_2, p_3) \sim \text{Dir}(\alpha_1, \alpha_2, \alpha_3)$

Veronimilhança:  $P(x_1, x_2, x_3 | p_1, p_2, p_3) = \text{Multinomial} \left( \begin{matrix} p_1, p_2, p_3 \\ x_1, x_2, x_3, n \end{matrix} \right)$

Posterior:

Tentou derivar o posterior, mas mostrou-se excessivamente nefudicado. Então vamos pelo óbvio: o que a Dirichlet é a priori conjugada da multinomial. Portanto o posterior será da forma:

$(p_1, \dots, p_K) | (x_1, \dots, x_n) \sim \text{Dirichlet}(\alpha_1 + x_1, \dots, \alpha_K + x_K)$ .

Nota cara.

• Posterior:

$$\begin{aligned} P(p_1, p_2, p_3 | x_1, x_2, x_3) &\propto p_1^{\alpha_1-1} p_2^{\alpha_2-1} p_3^{\alpha_3-1} \cdot p_1^{x_1} p_2^{x_2} p_3^{x_3} \\ &= p_1^{\alpha_1-1+x_1} p_2^{\alpha_2-1+x_2} p_3^{\alpha_3-1+x_3} \end{aligned}$$

Que é uma Dirichlet com parâmetros  $[\alpha_1 + x_1, \alpha_2 + x_2, \alpha_3 + x_3]$ .

• Posterior marginal:

As marginais são  $p_i \sim \text{Beta}(\alpha_i, \alpha - \alpha_i)$ . Logo:

$$* p_1 | (x_1, x_2, x_3) \sim \text{Beta}(\alpha_1 + x_1, \alpha_2 + x_2 + \alpha_3 + x_3).$$

$$* p_2 | (x_1, x_2, x_3) \sim \text{Beta}(\alpha_2 + x_2, \alpha_1 + x_1 + \alpha_3 + x_3),$$

$$* p_3 | (x_1, x_2, x_3) \sim \text{Beta}(\alpha_3 + x_3, \alpha_1 + x_1 + \alpha_2 + x_2),$$

$$\text{i)} \text{ PQ de } p_j - p_i \quad (i, j = 1, 2, 3, i \neq j)$$

Oft.: Esperança Dirichlet:

$$E(X_i) = \frac{\alpha_i}{\sum_{i=1}^n \alpha_i}$$

Então:

$$* \hat{p}_1 = \frac{\alpha_1 + x_1}{\alpha_1 + x_1 + \alpha_2 + x_2 + \alpha_3 + x_3}$$

$$* \hat{p}_2 = \frac{\alpha_2 + x_2}{\alpha_1 + x_1 + \alpha_2 + x_2 + \alpha_3 + x_3}$$

$$* \hat{p}_3 = \frac{\alpha_3 + x_3}{\alpha_1 + x_1 + \alpha_2 + x_2 + \alpha_3 + x_3}$$

Como a esperança é linear, basta tirar

$$\mathbb{E}[P_j - P_i] = \mathbb{E}[P_j] - \mathbb{E}[P_i], \text{ En que } \mathbb{E}[P_j] \text{ terá a mesma forma de } \mathbb{E}[P_i], \forall i, j \in \{1, 2, 3\}$$

1.1)

- i)  $H_0$ ) A droga não é melhor que o placebo:  $\theta \leq 0,25$
- $H_1$ ) A droga é superior ao placebo:  $\theta > 0,25$

ii)

Prior:  $U(0, 1)$ :  $P(\theta \leq 0,25) = 0,25$ ,  
 $P(\theta > 0,25) = 0,75$

$$\text{Odds relativa} = \frac{1 - 0,25}{0,25} = 3$$

Verossimilhança:

A uniforme é a prior conjugada de Beta. Portanto, este será o formato da verossimilhança. Para  $n=20$  e  $s=8$ , sob  $H_0$ , temos  $V \sim \text{Beta}(8, 12)$ .

Posterior:

Portanto, a posterior será justamente  $P \sim \text{Beta}(9, 13)$ .

Logo, testando as hipóteses:

$$* P(\theta \leq 0,25 | 8) = P[\text{Beta}(0,25 | 9, 13)] \{H_0\}$$

$$\text{Na R: } pbeta(0,25, 9, 13) = 0,0561 \dots$$

$$* \{H_2\} P(\theta > 0,25 | 8) = 1 - P[\text{Beta}(0,25 | 9, 13)]$$

$$\text{Na R: } 1 - pbeta(0,25, 9, 13) = 0,9438 \dots$$

Logo, a chance relativa posterior será:

$$\text{No R: } (1 - \text{pbeta}(0.25, 9, 13)) / (\text{pbeta}(0.25, 9, 13)) \\ = 16,81044.$$

Portanto, o Fator de Bayes será:

$$\frac{16,81044}{3} = \underline{\underline{5,60348}}.$$

iii)  $d = 1 \dots$  Rejetar;  $d = 0 \dots$  não rejetar

$\exists P(N = S_x + \text{andares rejetar } H_0; H_0 \text{ verdadeira que não rejetar } H_0; H_0 \text{ é falsa})$

Fazendo assim:  $L(d, \theta); R_{H_0} = R$ .

		Sim		Não	$\hat{N} R_g$ $H_0$
		A droga é eficaz	A droga não é eficaz		
Sim		$R_x$	$R_y$		$\hat{N} R_g$ $H_0$
	Não		$5R_y$	$R_x$	
			$R_y$		

Logo, a decisão "ótima" será rejeitar  $H_0$  caso:

$$P(\theta > 0,25 | S) > \frac{5R_y}{5R_y + R_y} = \frac{5}{6}$$

E, como  $P(\theta > 0,25 | g) = 0,9438 > 5/6$ ,

A decisão é p da rejeição de  $H_0$ ).

iv) A decisão de rejeitar  $H_0$  até sendo fortalecida  
pelo prior. Se tomarmos uma priori uniforme  
Beta(0,0); ou seja multilateral Veronimilhaga p. 21;  
(Não está no paradigma Bayesiano; mas na prática  
"dá no mané"); teríamos uma posterior Beta(8,12)  
(= Veronimilhaga).

No R:  $1 - \text{pbeta}(25, 8, 12) = 0,9225 \rightarrow 92\%$   
A decisão seria a mesma neste caso (Rejeita  $H_0$ ). Mas  
poderia mudar a decisão em outro exemplo...

### Linha 3.1

1) Vero:  $x_1, \dots, x_n \sim \text{Poisson}(\theta)$

$\theta \sim \text{Gama}(\alpha, \beta)$

$$\text{i) F.D.P} = \frac{\theta^k e^{-\theta}}{k!}, \text{ análoga: } \frac{\theta^x e^{-\theta}}{x!}$$

Então, a Veronimilhaga terá

$$L(x_i | \theta) = \prod_{i=1}^m \frac{\theta^{x_i} e^{-\theta}}{x_i!}, \quad e \quad \theta \in \mathbb{R}(\theta) = \frac{\theta^{\alpha-1} e^{-\beta\theta}}{\Gamma(\alpha)}$$

$$= \frac{\theta^{\sum x_i} e^{-\alpha\theta}}{\prod_{i=1}^m x_i!} \quad \alpha \theta^{\alpha-1} e^{-\beta\theta}.$$

Entre a posterior não perdeu as características da priori, com a conjugação com a verossimilhança:

Posterior:

$$\begin{aligned} P(\theta | x_1, \dots, x_n) &= \frac{\theta^{\sum_{i=1}^n x_i} e^{-n\theta}}{\Gamma(n)} \cdot \frac{\theta^{\alpha-1} e^{-\beta\theta}}{\Gamma(\alpha)} \\ &\propto \theta^{\sum_{i=1}^n x_i} e^{-n\theta} \cdot \theta^{\alpha-1} e^{-\beta\theta} \\ &\propto \theta^{\alpha + \sum_{i=1}^n x_i - 1} e^{-(\beta + n)\theta} \end{aligned}$$

Organizada da forma (\*), é fácil perceber que este posterior é uma Gamma( $\alpha + \sum_{i=1}^n x_i$ ,  $\beta + n$ )

$$= \text{Gamma}(\alpha^*, \beta^*)$$

\* Média: Média Gamma =  $\frac{\alpha}{\beta}$  (Def.). Então:

$$\text{Média posterior} = \frac{\alpha + \sum_{i=1}^n x_i}{\beta + n}$$

\* Variação: Variação Gamma =  $\frac{\alpha}{(\beta)^2}$  (Def.). Então:

$$\text{Var. Posterior} = \frac{\alpha + \sum_{i=1}^n x_i}{(\beta + n)^2}$$

$$\text{ii}) \alpha\bar{x} + (1-\alpha)\alpha^*\beta^{*-1} \quad (**)$$

$$\alpha^* = \alpha + \sum_i x_i; \beta^* = \beta + n. \quad \text{Se } \bar{x} = \frac{1}{n} \sum_i x_i;$$

$$\text{Então } \sum_i x_i = n\bar{x}.$$

$$(**) = \alpha\bar{x} + (1-\alpha)(\underbrace{\alpha + n\bar{x}}_{\alpha + \sum_i x_i - 1} / \underbrace{\beta + n}_{\beta^*}) \cdot \alpha \theta \cdot e^{-\beta^* \theta}$$

$\frac{\alpha}{\beta^*}; \alpha \text{ abranging toward } 0$

$$\rightarrow \underbrace{\alpha\bar{x}}_{\text{Dados}} + \underbrace{(1-\alpha)\alpha\beta^{-1}}_{\text{Prior}}.$$

O que mostra jecamente a posteriori: com a ponderação da informação, com a priori: ponderando por

$$\text{iii}) \text{ Pelo fato de no Beta, média } \frac{\alpha}{\beta} \text{ e Var } \frac{\alpha}{\beta^2};$$

Temos um domínio do priori, com a var. priori  $\rightarrow 0$ .

Dai, a posteriori  $\approx$  priori!

$$\text{iv}) \text{ C tq Var. Posteriori} = \alpha + \sum_i x_i / (\beta + n)^2 \rightarrow \frac{\alpha}{\beta^2} \text{ (Var. Priori).}$$

Sempre que  $\bar{x} \geq c$ .

$$\text{Sol: } \frac{\alpha + n\bar{x}}{(\beta + n)^2} \geq \frac{\alpha}{\beta^2}, \quad \frac{\alpha + n\bar{x}}{\beta^2 + n^2} \geq \frac{\alpha}{\beta^2}, \quad \frac{\alpha + \bar{x}}{n\beta^2} \geq \frac{\alpha}{\beta^2}$$

$$\rightarrow \frac{\alpha + \bar{x}}{n} \geq \alpha; \quad \alpha + \bar{x} \geq \alpha n; \quad \bar{x} \geq \alpha n - \alpha$$

$\bar{x} \geq \alpha(n-1)$

Lega, o c único real  $c = \alpha(n-1)$ .

Quando,  $\theta > 1$ , a média é maior que a (fórmula de prior); Então a variação posterior será maior que a variação prior, levando ao resultado desejado em iii).

3)  $x_1, \dots, x_n \sim \text{Poisson}(\theta)$ ;  
 $\theta \sim \text{Gamma}(1, 1)$ .

a) PQ  $\theta$ :

$$\text{Posterior} = \text{Gamma}(\alpha+1, \beta+1).$$

$$\text{Então: } \hat{\theta} = \frac{\alpha+1}{\beta+1}.$$

b) P. O. I.  $\theta$ :

$$\text{Moda posterior} = \frac{\alpha+1-1}{\beta+1} = \frac{\alpha}{\beta+1}.$$

c)  $\bar{x} = 1,55$  e  $n = 10$ , temos:

$$\frac{1}{10} \sum_{i=1}^m x_i = 1,55 ; \sum_i x_i = 15,5 = \alpha ; \alpha' = \alpha + 1 \therefore \alpha = 16,5.$$

$$\text{e, } \beta' = \beta + 1 = n + 1 - 10 + 1 = 11$$

Mediana Gamma(16,5, 11) Não tem fórmula fechada; No R: qgamma(0.5, 16.5, 11) = 1,4638...

①  $n=10$ ;  $\bar{x} = 1,55$ ; HPD 95%.

No R: q gamma (.025, 16.5, 11); q gamma (.975, 16.5, 11)

= ] 0,8657..., 2,3056... [ não é o intervalo HPD 95%.

5)

$$x_1, \dots, x_n \sim N(\mu, \phi^{-1})$$

$$\mu \sim N(\mu_0, \gamma^{-1}) \quad \phi^{-1} \text{ conhecida.} \quad \sigma_{\mu}^2 = \frac{1}{\gamma}$$

i) Posteriori de  $\mu$ .

Como  $\mu|N$  é a priori conjugada  $p|N(\mu, \phi^{-1})$   $\phi^2$  conhecido,  
a posteriori também será Normal, com média:

$$\frac{\bar{x} \cdot \frac{n}{\phi^2} + \mu_0 \frac{1}{\phi^2}}{\frac{n}{\phi^2} + \frac{1}{\phi^2}} \quad \text{E variância: } \frac{1}{\frac{n}{\phi^2} + \frac{1}{\phi^2}}; \quad \left| \begin{array}{l} \sigma_{\mu}^2 = \frac{1}{\gamma} \\ \sigma^2 = \frac{1}{\phi} \end{array} \right.$$

$$\text{Logo: } \mu | x_1, \dots, x_n \sim N \left[ \frac{\phi \bar{x} n + \mu_0 \gamma}{n \phi + \gamma}; \frac{1}{n \phi + \gamma} \right]$$

$$= \mu^*$$

ii):

$$w\bar{x} + (1-w)\mu_0^{(+)}$$

$$= \frac{\phi \bar{x} n + \gamma \mu_0}{n \phi + \gamma}, \text{ Se } w = \phi^n,$$

Temos que a forma (\*) não é uma ponderação da priori e a  
verosimilhança. (Med. amostral + Med. priore).

iii) Se  $\bar{x}_n$  é condicionalmente suficiente;

Então a predição terá a média da posterior; e

Variância da posterior será a variação de

$$x_{m+1}, \dots, x_{m+m} \Rightarrow \frac{\sigma^2}{m}$$

Logo, a predição de  $\bar{x}_m$  será:

$$\frac{1}{m} \sum_{i=1}^m x_i \mid x_1, \dots, x_m \sim N\left(\frac{\phi \bar{x}_n + \mu_0 \gamma}{n\phi + \gamma}, \frac{1}{n\phi + \gamma} + \frac{\sigma^2}{m}\right)$$

iv) Priori  $p(\mu) \propto 1 \quad \{ \text{isó. } \gamma \rightarrow 0 (\sigma_\mu^2 \rightarrow \infty) \}$

Neste caso, a variância de priori "Explodiu";  
Logo, a posteriori = Veronimillanca.

(Sugestivo para paradigmas Bayesiano e Freqüencial)

6)  $x_1, \dots, x_m \sim N(\mu, \phi^{-1})$ ,  $\phi^{-1}$  conhecida.

$$\mu \sim N(\mu_0, \gamma^{-1})$$

@ E.B. de  $\mu$  de:

i) P.Q.: Média posterior =  $\frac{\phi \bar{x}_n + \mu_0 \gamma}{n\phi + \gamma} \quad (**)$

ii) Perde aboluta: Mediana;  $\frac{n\phi + \gamma}{n\phi + \gamma}$

P/ normal; Mediana = Média =  $(**)$ .

iii) Perde O-S: Moda:

P/ normal: Moda = Mediana = Média =  $(**)$ .

6) HPD  $(1-\alpha) \cdot 100\%$ :  $\bar{p}/\mu$

Será:  $[\mu - z_{\frac{\alpha}{2}}, \mu + z_{\frac{\alpha}{2}}]$ ; onde  $z_{\frac{\alpha}{2}}$  é o quantil da normal padrão  $(0,1)$   
P/ dfa dargada.

### Lata 3.2

1)  $X \sim \text{Unif}(0, \theta+1) \quad \{-\infty < \theta < \infty\}$

a) Def: Uniforme  $(a, b)$ ;  $a \geq b$ .

Se  $b = a+1$ ;  $\text{Unif}(a, a+1) = \text{Unif}(a, b)$

Se  $a = 0$ ;  $\text{Unif}(0, \theta+1) = \text{Unif}(a, b)$

Logo, dado que  $\theta$  não constante,  $\theta$  não apenas um parâmetro de locação de  $X$ ; nem nenhuma pista de propriedade da distribuição  $\theta$ .

b) Com prior  $p(\theta) \propto 1$ , à posteriori de  $\theta$  não somente a verossimilhança. S. é., para uma amostra suficiente e ordenada de forma crescente;  $x^{(1)}, \dots, x^{(n)}$ ,

$P(\theta | x_1, \dots, x_n) \propto \begin{cases} x^{(1)} \leq \theta \leq x^{(n)} - 1 = 1 \\ 0, \text{ c.c.} \end{cases}$  Quer é uma uniforme

c) PQ = Média posterior =  $\frac{(x^{(n)} - 1) + x^{(1)}}{2}$

i)

(Uniforme)

\* Perde absolute: Mediana posterior  
 = Mediana uniforme  
 = Média uniforme  

$$= \frac{(x^{(n)} - 1) + x^{(1)}}{2}$$

iii) Intervalo HPD de  $\theta$   $100(1-\alpha)\%$ :

$$= \left[ x^{(1)} - \frac{\alpha}{2} (x^{(2)} - (x^{(n)} - 1)), x^{(n)} - 1 + \frac{\alpha}{2} (x^{(1)} - (x^{(n)} - 1)) \right]$$

Vinde que a uniforme é uma distribuição simétrica.

iii)  $P(\theta > \theta_0 | x_1, \dots, x_n) = \frac{x^{(2)} - \theta_0}{x^{(2)} - (x^{(n)} - 1)} = 1$

$$\Leftrightarrow x^{(2)} \leq \theta_0 \leq x^{(n)} - 1, \text{ o.c.c.}$$

2)  $x \sim \text{Unif}(0, \theta)$ ; ( $0 < \theta < \infty$ )

PDF Cdfif: 
$$\begin{cases} \frac{1}{\theta} & ; x \in [0, \theta] \\ 0 & , \text{o.c.c.} \end{cases}$$

$$\frac{1}{\theta - 0} = \frac{1}{\theta}$$

é a PDF de  $x$ .

Então,  $\sigma = \theta^{-1}$ ;  $\text{PDF}(\theta) = \theta \sim \text{Unif}(0, \frac{1}{\theta})$ .  
 Logo, p/k constante.  $Y \sim \text{Unif}\left(0, \frac{1}{\theta^2}\right)$  terá cubração.  
 $\frac{1}{\theta^2}$  logo,  $\theta$  por. de escala.

⑥ Priori:  $P(\theta) \propto \theta^{-1}$ .

Verosimilhança: Pluma amarra ordenada de  $X$  ob tam.  $n$ ;  $x^{(1)}, \dots, x^{(n)}$

$$\begin{aligned} L(\theta | x_1, \dots, x_n) &= \prod_{i=1}^n \theta^{-1} I(0 \leq x^{(i)} \leq \theta) \\ &= \theta^{-n} I(0 \leq x^{(n)} \leq \theta). \end{aligned}$$

Com priori  $\propto \theta^{-1}$ ; A Posteriori será:

$$\begin{aligned} P(\theta | x_1, \dots, x_n) &\propto \int_0^\infty \theta^{-n-1} I(0 \leq x^{(n)} \leq \theta) d\theta \\ &\propto \int_{x^{(n)}}^\infty \frac{1}{\theta^{n+1}} I[0 \leq x^{(n)} \leq \theta] d\theta \end{aligned}$$

Sabendo que  $\int \frac{1}{x^n} dx = \frac{x^{1-n}}{1-n} + C$  'nada trivial'

$$P(\theta | x_1, \dots, x_n) = \frac{n \hat{\theta}^n}{\hat{\theta}^{n+2}} I[0 \leq x^{(n)} \leq \theta] \quad \left\{ \hat{\theta} = x^{(n)} \right.$$

Que tem a forma de uma Pareto ( $x^{(n)}$  exda;  $n$  locaçao).

⑦ i)  $\bar{x}$  PQ = Média posteriori

$$= \text{Média Pareto} = \frac{\alpha x_m}{\alpha - 1}; \quad \alpha > 1$$

$$= \frac{n x^{(n)}}{n-1}; \quad n > 1$$

\* P.A. = Mediana Posterior

$$\text{Mediana Posterior} = x_m \sqrt[{\alpha/2}]{2}$$

$$= x^{(n)} \sqrt[{\alpha/2}]{2}$$

(ii) HPD de  $\theta$  p/ 100(1 -  $\alpha$ )% de credibilidade

Função quantil Posterior:  $x_m (1 - \rho)^{-\frac{1}{\alpha}}$

$= x^{(n)} (1 - \alpha)^{-1/n}$  é o quantil superior

p/ 100(1 -  $\alpha$ )% e  $x^{(n)}$  é o quantil inferior +  $\alpha$ .

③  $x_1, \dots, x_n | \theta \sim \text{Ber}(\theta)$

Def.: A priori de Jeffreys é proporcional a raiz quadrada do determinante da matriz de informação de Fisher.

$$\therefore \pi_\theta(\theta) \propto \sqrt{\det I_F(\theta)}$$

E a matriz de informação de Fisher é a esperança do quadrado da derivada da log-verossimilhança em relação a  $\theta$ , ou os negados da esperança de segundo derivada da log-verossimilhança em relação a  $\theta$ . I.e.

$$I_F(\theta) = E \left[ \left( \frac{\partial}{\partial \theta} \ln L(\theta) \right) \mid \theta \right] \quad \begin{array}{l} \text{Lembre que } L(\theta) \text{ é} \\ \text{a log-avariância} \\ \text{de } \theta. \end{array}$$

$$= -E \left[ \frac{\partial^2}{\partial \theta^2} \ln L(\theta) \mid \theta \right]$$

Para a Bernoulli( $\theta$ ), a variância é:

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i}$$

$$= \theta^{\sum x_i} (1-\theta)^{n-\sum x_i}$$

Logo;

$$L(\theta) = \sum_i x_i \ln(\theta) + (n - \sum_i x_i) \ln(1-\theta);$$

Lançada

$$\frac{\partial}{\partial \theta} L(\theta) = \frac{\sum x_i}{\theta} - \frac{n - \sum x_i}{1-\theta} \quad (*)$$

Dividindo mamente;

$$\frac{\partial}{\partial \theta} (*) = \frac{\sum x_i}{\theta^2} - \frac{n - \sum x_i}{(1-\theta)^2} \quad (**)$$

Sabendo que  $E(X) = \theta$ ,  
 $X \sim \text{Bernoulli}$ , então

$$I_F(\theta) = -E(**) = \frac{n}{\theta^2} - \frac{n - \theta n}{(1-\theta)^2}$$

$$= - \left[ \frac{n\theta}{\theta^2} - \frac{n - \theta n}{1-\theta^2} \right] = \frac{n}{\theta} + \frac{n(1-\theta)}{(1-\theta)\theta^2} = n \left( \frac{1}{\theta} + \frac{1}{1-\theta} \right)$$

Lega, a prior de Jeffreys tem a razão

Quadrada de  $I_F(\theta)$

$$\Rightarrow I_F(\theta) \propto \sqrt{n} \left( \frac{1}{\theta} + \frac{1}{1-\theta} \right)^2 = \sqrt{\frac{n}{\theta(1-\theta)}} \propto \sqrt{\frac{1}{\theta(1-\theta)}} = \frac{1}{\sqrt{\theta(1-\theta)}} \text{ é fixo}$$

$$\propto \frac{1}{\theta^{1/2} (1-\theta)^{1/2}} \sim \text{Beta}(1/2, 1/2),$$

Que está no suporte da Beta ( $\alpha, \beta > 0$ ).

Lega, esta prior é própria.

⑥ Verowillmarc:  $\theta^{\sum x_i} (1-\theta)^{n-\sum x_i}$

Posterior:

$$P(\theta | x_1, \dots, x_n) \propto \frac{\theta^{\sum x_i} (1-\theta)^{n-\sum x_i}}{\theta^{n/2} (1-\theta)^{n/2}}$$

$$\propto \theta^{\sum x_i - 1/2} (1-\theta)^{n-\sum x_i - 1/2}$$

Que é uma Beta  $(\sum x_i - 1/2 + 1, n - \sum x_i - 1/2 + 1)$

PO: Média Posterior

$$= \text{Média Beta} = \frac{\alpha}{\alpha+\beta}$$

$$= \frac{\sum x_i + 1/2}{\sum x_i + 1/2 + n - \sum x_i + 1/2} = \frac{\sum x_i + 1/2}{n+1}$$

23

Para achar o HPD (100(1- $\alpha$ )) de credibilidade para esta distribuição, basta tomar os quantis que contêm 100(1- $\alpha$ ) da densidade da distribuição. Para isso, deve-se saber  $n$  e  $\sum_i x_i$ .

## Lista 4

1)  $y_1, \dots, y_m \sim N(\mu, 1/\gamma)$  \* Anstoss  $\left| \lambda_0, \alpha_0, \beta_0 > 0 \right.$   
 $\mu | \gamma \sim N(\mu_0, \lambda_0 \gamma)$  \* Priori  $\mu$   
 $\gamma \sim \text{Gamma}(\alpha_0, \beta_0)$  \* Priori  $\gamma$

(a) • Veronimilhança:

$$\begin{aligned} L(y | \mu, \gamma) &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\gamma}{2}(y_i - \mu)^2\right) \\ &= \left(\frac{\gamma}{2\pi}\right)^{m/2} \exp\left(-\frac{\gamma}{2} \sum_{i=1}^m (y_i - \mu)^2\right) \end{aligned}$$

\* Priori  $\mu | \gamma$

$$\begin{aligned} L(\mu | \gamma) &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\lambda_0 \gamma}{2} (\mu - \mu_0)^2\right) \\ &= \frac{1}{\sqrt{\frac{\lambda_0 \gamma}{2\pi}}} \exp\left(-\frac{\lambda_0 \gamma}{2} (\mu - \mu_0)^2\right) \end{aligned}$$

\* Priori  $\gamma$

$$L(\gamma) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \gamma^{\alpha_0-1} \exp(-\beta_0 \gamma)$$

Portanto, a posteriori tem a corrélogia densidade  $f(\mu, \tau | y)$ :

$$P(\mu, \tau | y) \propto P(y | \mu, \tau) P(\mu | \tau) P(\tau)$$

$$\propto \left( \frac{\gamma}{2\pi} \right)^{n/2} \exp \left( -\frac{\gamma}{2} \sum_{i=1}^n (y_i - \mu)^2 \right).$$

$$\left( \frac{\lambda_0 \tau}{2\pi} \right)^{\alpha_0/2} \exp \left( -\frac{\lambda_0 \tau}{2} (\mu - \mu_0)^2 \right).$$

$$\frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} \exp(-\beta_0 \tau)$$

$$\propto \gamma^{n/2}$$

$$\tau^{n/2} \tau^{\alpha_0-2} \beta_0^{\alpha_0} \exp \left( -\frac{\gamma}{2} \sum_{i=1}^n (y_i - \mu)^2 - \frac{\lambda_0 \tau}{2} (\mu - \mu_0)^2 - \beta_0 \tau \right)$$

$$\propto \gamma^{\left(\frac{n+1}{2}\right) + \alpha_0 - 1} \exp \left\{ -\frac{\gamma}{2} \left[ \left( \sum_{i=1}^n (y_i - \mu)^2 \right) - \lambda_0 (\mu - \mu_0)^2 \right] - \beta_0 \tau \right\}$$

$$\text{Salando que } \int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}, \quad e^{\int_{-\infty}^{\infty} e^{-\frac{(x+\theta)^2}{c^2}} dx} = c \sqrt{\pi},$$

definimos a integral gaussiana, consideraros o quadrado em  $\exp(-)$  para terás integrais.

Ignorando por enquanto  $\gamma^{\frac{(n+1) + \alpha_0 - 1}{2}}$ , temos:

$$\exp \left( -\frac{\gamma}{2} \left( \left( \sum_{i=1}^n (y_i - \mu)^2 \right) - \lambda_0 (\mu - \mu_0)^2 \right) - \beta_0 \tau \right)$$

$$= \exp \left( -\frac{\gamma}{2} \left( \sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2 + \lambda_0 \mu_0^2 - 2\lambda_0 \mu_0 \mu + \lambda_0 \mu^2 \right) - \beta_0 \tau \right)$$

$$= \exp\left(-\frac{\gamma}{2}\left(\mu^2/(n+\lambda_0) - 2\mu\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right) + \sum_{i=1}^n y_i^2 + \lambda_0 \mu_0^2\right) - \beta_0 \gamma\right)$$

completando quadrado

$$\underbrace{\mu^2(n+\lambda_0)}_{x = \mu}, \underbrace{-2\mu\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right)}_{b = -2\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right)}, \underbrace{\sum_{i=1}^n y_i^2 + \lambda_0 \mu_0^2}_{a = n+\lambda_0}, \underbrace{ax^2 + bx + c}_{c = \dots}$$

$$x = \mu, x^2 = \mu^2; b = -2\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right); c = \dots$$

Então, queremos  $a(x-h)^2 + K$

$$(n+\lambda_0)(\mu - h)^2 + K$$

$$h = \frac{-b}{2a} \quad \text{e} \quad K = c - \frac{b^2}{4a}$$

$$(n+\lambda_0) \left( \mu - \frac{2\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right)}{2(n+\lambda_0)} \right)^2 + \sum_{i=1}^n y_i^2 + \lambda_0 \mu_0^2 - \frac{4\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right)^2}{4(n+\lambda_0)}$$

$$= (n+\lambda_0) \left( \mu - \frac{\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right)}{n+\lambda_0} \right)^2 + \sum_{i=1}^n y_i^2 + \lambda_0 \mu_0^2 - \frac{\left(\sum_{i=1}^n y_i + \lambda_0 \mu_0\right)^2}{n+\lambda_0}$$

\* V. de Oliveira

$$\exp\left(-\frac{\gamma}{2}\left(\mu^2(n-\lambda_0) - 2\mu\left(\sum_{i=1}^n y_i - \lambda_0 \mu_0\right) + \sum_{i=1}^n y_i^2 + \lambda_0 \mu_0^2\right) - \beta_0 \gamma\right)$$

$$= \exp\left\{-\frac{\gamma}{2}\left(\frac{(n+\lambda_0)\left(\mu - \frac{\sum_{i=1}^n y_i - \lambda_0 \mu_0}{n+\lambda_0}\right)^2 + \sum_{i=1}^n y_i^2 + \lambda_0 \mu_0^2 - \left(\sum_{i=1}^n y_i + \lambda_0 \mu_0\right)^2}{n-\lambda_0} - \beta_0 \gamma\right)\right\}$$

Lembrei:

$$\int_{-\infty}^{\infty} \gamma^{\left(\frac{n+\lambda_0}{2}\right) + q_0 - 1} \exp(-\gamma) d\mu$$

$$\propto \int_{-\infty}^{\infty} \exp\left(-\frac{\gamma(n+\lambda_0)}{2}\left(\mu - \frac{\sum_{i=1}^n y_i - \lambda_0 \mu_0}{n+\lambda_0}\right)\right) d\mu = (*)$$

Lembra que é o integral

$$\text{Gaussiana: } \int_{-\infty}^{\infty} e^{-\frac{(x-b)^2}{c^2}} dx = c\sqrt{\pi}; \quad b = \frac{\sum_{i=1}^n y_i - \lambda_0 \mu_0}{n+\lambda_0};$$

Tendo que

$$(*) = \sqrt{\frac{2\pi}{\gamma(n+\lambda_0)}}$$

$$c = \left(\frac{\gamma(n+\lambda_0)}{2}\right)^{-\frac{1}{2}}$$

Este é a marginal  $P(Y|D)$ . 27

Para a marginal  $P(Y|D)$ , consideraremos  
constante = marginal anterior, tal que

$$P(Y|D) \propto \gamma^{\frac{(n+1)+\alpha_0-1}{2}} \exp \left( -\frac{\gamma}{2} \left( \sum_{i=1}^n y_i + \lambda_0 \mu_0^2 - \frac{\left( \sum_{i=1}^n y_i + \lambda_0 \mu_0 \right)^2}{m+\lambda_0} \right) / \beta_0 \right)$$

Gama:  $\beta^{-\alpha}$

$$\frac{1}{\Gamma(\alpha)} x^{\alpha-1} \exp(-\beta x), \text{ da Gama } (\alpha, \beta)$$

Se  $\gamma \sim \text{Gama } (\alpha, \beta)$

$$\beta = \beta_0 + \left( \frac{\sum_{i=1}^n y_i + \lambda_0 \mu_0^2 - \frac{\left( \sum_{i=1}^n y_i + \lambda_0 \mu_0 \right)^2}{m+\lambda_0}}{m+\lambda_0} \right)^2$$

$$\alpha = \alpha_0 + \frac{n+1-1}{2} = \alpha_0 + \frac{n}{2}$$

Logo;  $Y|D \sim \text{Gama} \left( \alpha_0 + \frac{n}{2}, \beta_0 + \sum_{i=1}^n y_i + \lambda_0 \mu_0^2 - \left( \sum_{i=1}^n y_i + \lambda_0 \mu_0 \right)^2 \right)$

Por fim; Esse é um resultado Normal  $\frac{Y|D}{\text{Gama}}$

$$\text{Então: } \nu | Y, D \sim \text{Normal} \left( \frac{\bar{x} \cdot \frac{n}{\sigma^2} + \mu_0 \frac{1}{\sigma_p^2}}{\frac{n}{\sigma^2} + \frac{1}{\sigma_p^2}}, \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\sigma_p^2}} \right)$$

$$\Rightarrow \nu | Y, D \sim N \left( \frac{\bar{y} n + \mu_0 \lambda_0}{n + \lambda_0}; \frac{1}{(\lambda_0 + n) T} \right) \quad \square$$

⑥ A posteriori segue progressiva com a priori não informativa, visto que contém no mundo de mundo com este convulsão.

Neste caso, com a variação de prior esgotado, teremos a convergência do método Bayesiano com o método fragmentado.

② ③ Por definição, a Dirichlet não converge ( $\Rightarrow \alpha_i > 0 \forall i$ ).

Prova: Com f. v. priori

$$P(\theta) \propto \prod_{i=1}^K \theta_i^{-1}$$

E veramplitude Multimodal

$$P(n|\theta) \propto \prod_{i=1}^K \theta_i^{n_i}$$

A posteriori será:

$$P(\theta|n) \propto \prod_{i=1}^K \theta_i^{n_i - 1}$$

Se, para algum  $n_i = 0$ ; teremos  
algum termo  $\frac{1}{n_i}$ ; que resultará  
na divergência de integral. □

$$\textcircled{3} \quad A = 467; W = 315; O = 109; n = 891$$

Então:  $X \sim \text{Multinomial}\left(\frac{467}{891}, \frac{315}{891}, \frac{109}{891}\right)$

Tomando uma prior (conjugada) Dirichlet "muito informativa"  $\alpha = (1, 2, 2)$ .

Agora, temos uma posterior Dirichlet  $(468+1, 316+2, 110+2)$ .

Lem:  $P(\theta|n) \sim \text{Dirichlet}(468, 316, 110)$ .

a)  $P(\theta_i) > 0,5 \Rightarrow$  Via numerações na R, podemos fazer:  
 $\rightarrow \text{Dirichlet Reg: } \text{rdirichlet}(10000, c(468, 316, 110))$

Que irá retornar uma matriz de probabilidades. Observando ent.

vemos que a probabilidade de número de algumas proporções  $\theta_1 \geq 0,5$  é  $\approx 0,9183$ . Nota: Total de  $\theta_1$  é cerca de 150 (utilizada: 150 + 67636 [minha medida])

b)  $P(\theta_1) > 0,5 \approx 0,92$ , conforme direito do acima.

c) Tomando a média das numerosas acima, vemos que

\* Média Agnelo  $\approx 0,5232744$

\* Média Walican  $\approx 0,353678$

$\rightarrow$  Diferença  $\approx 0,17$ .

Média

## Lata 5

$$\textcircled{2} \quad \eta \sim N(0,1); \quad \eta = \ln\left(\frac{p}{1-p}\right)$$

Logo,  $p = \frac{e^\eta}{1 + e^\eta}$

Come a verossimilitudine da Bernoulli é dada por:

$$P(y|p) = \binom{n}{y} p^y (1-p)^{n-y} \quad \text{Fixando } n=12; y=9;$$

$$P(9|p) = \binom{12}{9} p^9 (1-p)^3$$

$$= \frac{12!}{(12-9)! 9!} p^9 (1-p)^3$$

$$= \frac{12 \cdot 11 \cdot 10 \cdot 9!}{3! 9!} p^9 (1-p)^3$$

$$= 220 p^9 (1-p)^3$$

Quanto caro, vero?

$$P(9) = 220 \cdot \frac{e^{\eta+9}}{1+e^\eta} \cdot \left(1 - \frac{e^\eta}{1+e^\eta}\right)^3; \quad \eta \sim N(0,1)$$

Implementar a nova função como:

$$> \text{sd} = 1; \quad \text{eta} = \text{rnorm}(1, \text{sd}=\text{sd})$$

$$> 220 * ((\exp(\text{eta}) / (1 + \exp(\text{eta})))^9 * ((1 - (\exp(\text{eta}) / (1 + \exp(\text{eta}))))^3)$$

$P$ /Ouffian  $\sigma^2 = 4, \sigma = 2$ , bala negra  $> d = 2$  (an)  $\geq d = 3$ .

P/ verificar para  $\sigma^2 = 4$  e  $\sigma^2 = 9$ ; basta mudar o valor de  $s_d$ :  
 $s_d = 2$  | ou  $s_d = 3$

Notamos que foi operando ao longo do curvo sobre posteriores; em reje. quanto menor é a variância da priori, menor é a massa. Ela é. Neste caso, os valores de posteriores são cada vez mais incertos.

