

Inferência para a média de uma  
distribuição Normal  
com variância desconhecida: O  
modelo Normal-NormalGama

# Definição do Problema

Considere como antes  $X_1, \dots, X_n \mid \mu, \sigma^2 \stackrel{iid}{\sim} N(\mu, \sigma^2)$ , mas agora tanto a média  $\mu$  quanto a variância  $\sigma^2$  são desconhecidas, i.é. o parâmetro  $\theta = (\mu, \sigma^2)$  tem dimensão 2. Usualmente o foco da inferência é o parâmetro  $\mu$  e  $\sigma^2$  é chamado um parâmetro *nuissance* ou *de estorvo*.

Como vimos na Seção anterior, a notação fica mais simples quando o problema é parametrizado em termos da precisão  $\phi = \sigma^{-2}$ , de forma que pensamos numa amostra  $X_1, \dots, X_n \mid \mu, \phi \stackrel{iid}{\sim} N(\mu, \phi^{-1})$ .

É natural que especificar uma distribuição a priori bivariada  $p(\mu, \phi)$  é mais difícil que especificar uma univariada, como foi o caso de  $p(\theta)$  na Seção ?? ou de  $p(\mu)$  na Seção 1.1. Uma opção conveniente é partir o problema em “pedazos” univariados, especificando sucessivamente  $p(\mu \mid \phi)$  e  $p(\phi)$  (essa ideia de “*dividir para conquistar*” é muito útil em modelagem e, de fato, vamos usar ela extensivamente para abordar o problema de *modelos hierárquicos* nas próximas unidades).

# Calculando a condicional $\mu \mid \phi$

Começamos assim pela distribuição a priori condicional de  $\mu \mid \phi$ . Quando condicionamos no valor de  $\phi$  (ou, equivalentemente, no valor de  $\sigma^2 = \phi^{-1}$ ), o problema passa a ser o que estudamos na Seção anterior. Dessa forma, sabemos que a distribuição conjugada  $p(\mu, \phi)$  deve satisfazer que a condicional de  $\mu \mid \phi$  deve ser Normal e também que a distribuição a posteriori condicional de  $\mu \mid x_1, \dots, x_n; \phi$  é Normal com média e variância dadas pelas equações (2) e (3).

Suponha que parametrizamos a distribuição a priori condicional de forma que  $\mu \mid \phi \sim \text{Normal}(\mu_0, (\lambda_0 \phi)^{-1})$ . Substituindo  $\sigma^2$  por  $\phi^{-1}$  e  $\tau^2$  por  $(\lambda_0 \phi)^{-1}$  nas equações (2) e (3), o comentário anterior implica que, a posteriori,  $\mu \mid \phi, x_1, \dots, x_n \sim \text{Normal}(\mu^*, (\lambda^* \phi)^{-1})$ , onde

$$\mu^* = \frac{\lambda_0 \mu_0 + n \bar{x}}{\lambda_0 + n} \quad \lambda^* = \lambda_0 + n$$

Dessa forma, resolvemos o problema da distribuição a priori condicional de  $\mu \mid \phi$  e também o de calcular a posteriori condicional de  $\mu \mid \phi, x_1, \dots, x_n$ .

# Calculando a marginal de $\phi$

Resta especificar a distribuição a priori marginal de  $\phi$  e calcular a distribuição a posteriori também marginal de  $\phi | x_1, \dots, x_n$ . Por enquanto, considere o caso com uma priori  $p(\phi)$  geral.

Lembre primeiro que  $[\bar{X} = \sum_{i=1}^n X_i, S^2 = \sum_{i=1}^n (X_i - \bar{X})^2]$  é um estatístico suficiente e que, dado o par  $(\mu, \phi)$ ,  $\bar{X}$  e  $S^2$  são independentes com  $\bar{X} | \mu, \phi \sim \text{Normal}[\mu, (n\phi)^{-1}]$  e  $\phi S^2 | \mu, \phi \sim \chi_{n-1}^2 \equiv \text{Gama}(\frac{n-1}{2}, \frac{1}{2})$ . Logo, a verossimilhança é

$$\begin{aligned} p(x_1, \dots, x_n | \mu, \phi) &\propto p(\bar{x}, S^2 | \mu, \phi) \propto p(\bar{x} | \mu, \phi) p(S^2 | \mu, \phi) \\ &\propto \phi^{1/2} \exp \left\{ -\frac{n\phi}{2} (\bar{x} - \mu)^2 \right\} \times \phi^{(n-1)/2} \exp \left\{ -\frac{\phi}{2} s^2 \right\} \\ &\propto \phi^{n/2} \exp \left\{ -\frac{\phi}{2} [s^2 + (\mu - \bar{x})^2] \right\}. \end{aligned}$$

# Chegando à conjunta de $\mu$ e $\phi$

Por outra parte, como especificamos que  $\mu | \phi \sim \text{Normal}(\mu_0, (\lambda_0 \phi)^{-1})$ , segue que a densidade a priori conjunta é

$$p(\mu, \phi) = p(\phi) p(\mu | \phi) \propto p(\phi) \phi^{1/2} \exp \left\{ -\frac{\phi}{2} \lambda_0 (\mu - \mu_0)^2 \right\}. \quad (9)$$

$$\begin{aligned} p(\mu, \phi | x_1, \dots, x_n) &\propto p(\mu, \phi) p(x_1, \dots, x_n | \mu, \phi) \\ &\propto p(\phi) \phi^{(n+1)/2} \exp \left\{ -\frac{\phi}{2} [s^2 + (\mu - \bar{x})^2 + \lambda_0 (\mu - \mu_0)^2] \right\}. \end{aligned} \quad (10)$$

Finalmente, usando o fato que  $\mu | \phi, x_1, \dots, x_n \sim \text{Normal}(\mu^*, (\lambda^* \phi)^{-1})$ ,

# A posteriori marginal de $\phi$

$$\begin{aligned} p(\phi | x_1, \dots, x_n) &= \frac{p(\mu, \phi | x_1, \dots, x_n)}{p(\mu | \phi, x_1, \dots, x_n)} \\ &\propto p(\phi) \frac{\phi^{(n+1)/2} \exp \left\{ -\frac{\phi}{2} [s^2 + (\mu - \bar{x})^2 + \lambda_0 (\mu - \mu_0)^2] \right\}}{\phi^{1/2} \exp \left\{ -\frac{\phi}{2} \lambda^* (\mu - \mu^*)^2 \right\}} \\ &\propto p(\phi) \phi^{n/2} \exp \left\{ -\frac{\phi}{2} [s^2 + (\mu - \bar{x})^2 + \lambda_0 (\mu - \mu_0)^2 - \lambda^* (\mu - \mu^*)^2] \right\} \\ \text{Veja o núcleo da Gama } \rightarrow &\propto p(\phi) \left[ \phi^{n/2} \exp \left\{ -\frac{\phi}{2} \left[ s^2 + \frac{n \lambda_0}{\lambda_0 + n} (\bar{x} - \mu_0)^2 \right] \right\} \right] \quad (11) \end{aligned}$$

(para o cálculo acima, da equação é útil observar que o termo da esquerda depende somente de  $\phi$ , enquanto o da direita depende também de  $\mu$ . A equação 11 é portanto uma identidade que vale para todo  $\mu$ . Em termos práticos, na direita é possível substituir  $\mu$  por qualquer valor e o resultado final deveria ser o mesmo. Fazer a substituição  $\mu = \bar{x}$  ou  $\mu = \mu_0$  facilita o cálculo).

# Quais as regras de atualização?

**Proposição 1.** *Suponha que  $X_1, \dots, X_n \mid \mu, \phi \stackrel{iid}{\sim} \text{Normal}(\mu, \phi^{-1})$  e, a priori,  $\mu \mid \phi \sim \text{Normal}(\mu_0, (\lambda_0 \phi)^{-1})$  e  $\phi \sim \text{Gama}(\alpha_0, \beta_0)$ . Então, a posteriori,  $\mu \mid \phi, x_1, \dots, x_n \sim \text{Normal}(\mu^*, (\lambda^* \phi)^{-1})$  e  $\phi \mid x_1, \dots, x_n \sim \text{Gama}(\alpha^*, \beta^*)$ , onde  $\mu^*$  e  $\lambda^*$  são dados nas equações (6) e (7) e*

$$\alpha^* = \alpha_0 + \frac{n}{2}, \quad (12)$$

$$\beta^* = \beta_0 + \frac{1}{2} s^2 + \frac{n \lambda_0}{2(\lambda_0 + n)} (\bar{x} - \mu_0)^2. \quad (13)$$

# Prova da regra de atualização

*Demonstração.* Como foi explicado acima das equações (6) e (7), a parte referente à  $p(\mu | \phi, x_1, \dots, x_n)$  é consequência da Seção 1.1. Para achar a distribuição a posteriori marginal de  $\phi$ , substitua  $p(\phi) \propto \phi^{\alpha-1} e^{-\beta_0 \phi}$  na equação (11) para obter que

$$p(\phi | x_1, \dots, x_n) \propto \phi^{\alpha_0+n/2-1} \exp \left\{ -\phi \left[ \beta_0 + \frac{1}{2} s^2 + \frac{n \lambda_0 (\bar{x} - \mu_0)^2}{2(\lambda_0 + n)} \right] \right\}, \quad (14)$$

o que implica que  $\phi | x_1, \dots, x_n \sim \text{Gamma}(\alpha^*, \beta^*)$  □



# Posteriori Marginal de $\mu$

Como mencionamos no início desta Seção, usualmente o interesse é no parâmetro  $\mu$ . Nesse caso, precisamos da distribuição a posteriori marginal  $p(\mu | x_1, \dots, x_n)$ .

Segue da proposição 1 que, dado  $x_1, \dots, x_n$ ,  $Z = (\lambda^* \phi)^{1/2} (\mu - \mu^*)$  segue uma distribuição Normal Padrão. Considere então a distribuição a posteriori conjunta de  $(Z, \phi)$ . O Jacobiano da transformação de  $(Z, \phi) \mapsto (\mu = \mu^* + (\lambda^* \phi)^{-1/2} Z; \phi)$  é  $(\lambda^* \phi)^{-1/2} \propto \phi^{-1/2}$ . Logo, a densidade a posteriori de  $(Z, \phi)$  é

$$\begin{aligned} p(Z, \phi | x_1, \dots, x_n) &\propto p(\mu, \phi | x_1, \dots, x_n) \left| \frac{\partial (\mu, \phi)}{\partial (Z, \phi)} \right| \\ &\propto p(\mu | \phi, x_1, \dots, x_n) p(\phi, x_1, \dots, x_n) \phi^{-1/2} \\ &\propto \phi^{1/2} \exp \left\{ -\frac{\lambda^* \phi}{2} (\mu - \mu^*)^2 \right\} \times \phi^{\alpha^* - 1} \exp\{-\beta^* \phi\} \times \phi^{-1/2} \\ &\propto \exp \left\{ -\frac{1}{2} z^2 \right\} \times \phi^{\alpha^* - 1} \exp\{-\beta^* \phi\}. \end{aligned}$$

# Posteriori Marginal de $\mu$

Logo, a posteriori,  $Z$  e  $\phi$  são independentes com  $Z | x_1, \dots, x_n \sim N(0,1)$  e, como já sabíamos,  $\phi | x_1, \dots, x_n \sim \text{Gama}(\alpha^*, \beta^*)$ . Das propriedades da distribuição Gama sabemos que isso implica que  $2\beta^* \phi | x_1, \dots, x_n \sim \text{Gama}(\alpha^*, 1/2)$ , também denominada de distribuição  $\chi^2$  com  $(2\alpha^*)$  graus de liberdade. Da definição da distribuição  $t$  de Student como a razão entre duas variáveis aleatórias independentes, uma com distribuição Normal(0,1) e a outra sendo a raiz quadrada de uma  $\chi_m^2$  dividida pelos graus de liberdade  $m$ , segue que

$$\sqrt{\frac{\lambda^* \alpha^*}{\beta^*}} (\mu - \mu^*) = \frac{Z}{\sqrt{2\beta^* \phi / (2\alpha^*)}} | x_1, \dots, x_n \sim t_{2\alpha^*}.$$

Note que, como a distribuição a priori e a posteriori pertencem a mesma família Normal-Gama, um resultado semelhante deve valer também para a distribuição a priori marginal de  $\mu$ . É conveniente escrever o resultado para uso futuro (veja, por exemplo, a subseção 1.2.3).

# Resumindo num lema

**Lema 2.** *Suponha que  $\mu | \phi \sim \text{Normal}(\mu_0, (\lambda_0 \phi)^{-1})$  e  $\phi \sim \text{Gama}(\alpha_0, \beta_0)$ , onde  $\alpha$ ,  $\beta$ ,  $\lambda_0$  e  $\phi$  são parâmetros positivos. Então*

$$\sqrt{\frac{\lambda_0 \alpha}{\beta}} (\mu - \mu_0) \sim t_{2\alpha}. \quad (16)$$

# Tornando a priori não informativa

O intervalo de intervalo de confiança clássico para  $\mu$  é

$$\bar{x} \pm t_{n-1; \alpha/2} \frac{s}{\sqrt{n(n-1)}}, \quad \begin{array}{l} \text{S é só a soma, sem} \\ \text{Dividir por } n-1. \end{array} \quad (17)$$

Com base na distribuição (15), o equivalente bayesiano desse intervalo de confiança seria

$$\mu^* \pm t_{2\alpha^*; \alpha/2} \sqrt{\frac{\beta^*}{\lambda^* \alpha^*}}, \quad (18)$$

# Quais valores dos hiperparâmetros?

Tem valores de  $(\mu_0, \lambda_0, \alpha_0, \beta_0)$  para quais (17) e (18) são iguais?

$2\alpha^* = 2\alpha_0 + n$  teria que ser igual a  $(n - 1)$ , isto é  $\alpha_0 = -(1/2)$

$\mu^* = \bar{x}$ , e da equação (2) obtemos então  $\lambda_0 = 0$  Assim o valor de  $\mu_0$  não importa

$$\frac{s}{\sqrt{n(n-1)}} = \sqrt{\frac{\beta^*}{\lambda^* \alpha^*}} = \sqrt{\frac{\beta_0 + \frac{1}{2} s^2 + \frac{n \lambda_0}{2(\lambda_0 + n)} (\bar{x} - \mu_0)^2}{(\lambda_0 + n)(\alpha_0 + n/2)}}$$

$\alpha_0 = -(1/2)$  e  $\lambda_0 = 0$  dá  $\beta_0 = 0$ . É chamada de priori matching, nesse caso não informativa.

Um problema, porém, é que nem a distribuição Normal está bem definida para variância infinita (i.e. precisão  $\lambda_0 \phi = 0$ ), nem a distribuição Gama está definida quando  $\alpha_0 = -(1/2) \leq 0$  e/ou  $\beta_0 = 0 \leq 0$ . Nesse sentido, veja que da equação (9) temos que

# Substituindo os valores

$$\begin{aligned} p(\mu, \phi) &\propto \phi^{\alpha_0-1} \exp\{-\beta_0 \phi\} \times \phi^{1/2} \exp\left\{-\frac{\phi}{2} \lambda_0 (\mu - \mu_0)^2\right\} \\ &\propto \phi^{\alpha_0-1/2} \exp\left\{-\frac{\phi}{2} \lambda_0 (\mu - \mu_0)^2 - \beta_0 \phi\right\} \end{aligned}$$

Leva a  $p(\mu, \phi) \propto \frac{1}{\phi}$ , Que é imprópria.

Veja que pode ser pensada como  $p(\mu, \phi) \propto p(\mu) \times p(\phi) \propto 1 \times \phi^{-1}$

isto é, a priori  $\mu$  e  $\phi$  seriam independentes com  $p(\mu) \propto 1$  e  $p(\phi) \propto \phi^{-1}$ .

# Distribuição Preditiva

O problema do cálculo de distribuições preditivas no caso desta Seção pode tomar a seguinte forma, semelhante à que foi discutida na Seção 1.1. Considere  $X_1, \dots, X_n, X_{n+1}, \dots, X_{n+m} \mid \mu, \phi \stackrel{iid}{\sim} \text{Normal}(\mu, (\lambda \phi)^{-1})$  com a distribuição a priori  $\mu \mid \phi \sim \text{Normal}(\mu_0, (\lambda_0 \phi)^{-1})$  e  $\phi \sim \text{Gama}(\alpha_0, \beta_0)$ . Com base na observação de  $x_1, \dots, x_n$  desejamos prever  $\bar{X}_{(n+1):(n+m)} = m^{-1} \sum_{i=n+1}^{m+n} X_i$  ou, em outras palavras, procuramos a distribuição condicional de  $\bar{X}_{(n+1):(n+m)}$  dado  $x_1, \dots, x_n$ .

Da subseção 1.1.2 sabemos que  $\bar{X}_{(n+1):(n+m)} \mid x_1, \dots, x_n; \phi \sim \text{Normal}[\mu^*, (\lambda^* \phi)^{-1}]$ . Por outro lado, da subseção ??, sabemos também que  $\phi \mid x_1, \dots, x_n \sim \text{Gama}(\alpha^*, \beta^*)$ .

Portanto, se olharmos o par  $(\bar{X}_{(n+1):(n+m)}, \phi)$  condicionado a  $x_1, \dots, x_n$ , temos uma distribuição Normal-Gama e o Lema 2 implica que

$$\sqrt{\frac{(\frac{1}{m} + \frac{1}{\lambda^*}) \alpha^*}{\beta^*}} (\bar{X}_{(n+1):(n+m)} - \mu^*) \mid x_1, \dots, x_n \sim t_{2\alpha^*}.$$

# Previsão para a velocidade da luz

**Exemplo 2** (Continuação). Como a distribuição a posteriori de  $\mu$  [equação (15)] é simétrica com respeito a  $\mu^*$ , segue que a estimativa bayesiana com respeito a PQ, PA ou perda zero-um é  $\mu^* = 27.75$ .