

Prioris, Prioris Conjugadas,
Prioris não informativas e
Distribuições Preditivas

Comentários Gerais sobre Prioris

- Prioris e posterioris não são absolutos. Podem mudar de acordo com a informação disponível ao analista.
- Suponha uma observação (x, y) com verossimilhança $p(x, y | \theta) = p(x | \theta) p(y | x, \theta)$.
 - $p(\theta | x) \propto p(\theta) p(x | \theta)$
 - $p(\theta | x, y) \propto p(\theta) p(x, y | \theta) \propto \{p(\theta) p(x | \theta)\} p(y | x, \theta)$

Recomenda-se que prioris sejam fundamentadas em observações de experimentos anteriores.

A melhor priori a usar pode mudar dependendo do problema sob estudo.

- Visto que $p(\theta | x) \propto p(\theta) p(x | \theta)$, devemos concentrar o esforço para especificar *elucidar* / *elicitate* a priori na região onde (esperamos que) a verossimilhança vai ser significativamente maior do que zero.

Questiono essa última afirmação. (Pessoa procurando chaves)

Famílias Conjugadas

- Exponential family: $p(x | \theta) \propto c(\theta) \exp\{\sum_{j=1}^p T_j(x)\eta_j(\theta)\}$;
- Uma priori da forma $p(\theta) \propto b(\theta) \exp\{\sum_{j=1}^p \alpha_j \eta_j(\theta)\}$ vai ser conjugada;

Usualmente chama de família conjugada natural.

- Beta-Binomial, Multinomial-Dirichlet, Poisson-Gama, Exponencial-Gama (mais geral: Gama com α fixo-Gama); Normal-Normal (variância conhecida), Normal-Normal-Gama (precisão desconhecida) etc.
- Priori conjugada fora de famílias exponenciais: Uniforme(0, θ)-Pareto

Inferência para a média de uma Normal com variância conhecida

$$p(x_1, \dots, x_n | \mu) \propto \exp\left\{-\sum_{i=1}^n (x_i - \mu)^2 / 2\sigma^2\right\} \quad p(\bar{x} | \mu) \propto \exp\left\{\frac{-n}{2\sigma^2}(\bar{x} - \mu)^2\right\}$$

Considere $X_1, \dots, X_n | \mu \stackrel{iid}{\sim} N(\mu, \sigma^2)$ com σ^2 conhecida e suponha que a priori $\mu \sim N(\mu_0, \tau^2)$. Para calcular a distribuição a posteriori o seguinte Lema será muito útil.

Um Lema útil

Lema 1. *Seja Y uma variável aleatória que toma valores em toda a reta real tal que a sua densidade é $f(y) = k e^{-Q(y)}$, onde k é uma constante que não depende de y e $Q(y) = ay^2 + by + c$ ($a > 0$) é uma forma quadrática em y . Logo, Y segue uma distribuição Normal com média e variância*

$$\mathbb{E}(Y) = -\frac{b}{2a} = -\frac{Q'(0)}{Q''(0)} \quad \text{e} \quad \text{Var}(Y) = \frac{1}{2a} = \frac{1}{Q''(0)}.$$

Demonstração: Primeiro complete o quadrado.

$$ay^2 + by + c = a \left(y + \frac{b}{2a} \right)^2 + c - \frac{b^2}{4a}, \quad \text{assim} \quad f(y) = k' \exp \left\{ -a \left(y + \frac{b}{2a} \right)^2 \right\},$$

onde $k' = k \exp\{c - b^2/(4a)\}$ continua sendo uma constante que não depende de y . Dessa forma, a densidade de y é proporcional a uma densidade Normal com média $\mu = -\frac{b}{2a}$ e variância $\sigma^2 = \frac{1}{2a}$ e, como é uma densidade, a constante de proporcionalidade tem que ser igual a um. \square

Usando o lema para calcular a posteriori

Retornando ao problema do início desta Seção, para achar a distribuição a posteriori note que (i) $p(\mu) \propto \exp\{-\frac{1}{2\tau^2} (\mu - \mu_0)^2\}$ e (ii) como $\bar{x} = \sum_{i=1}^n x_i$ é um estatístico suficiente e $\bar{x} | \mu \sim N(\mu, \sigma^2/n)$, $p(x_1, \dots, x_n | \mu) \propto p(\bar{x} | \mu) \propto \exp\{-\frac{n}{2\sigma^2} (\bar{x} - \mu)^2\}$ (aqui e em todo o exemplo “ \propto ” significa “proporcional a menos de uma constante que não depende de μ ”). Logo,

$$\begin{aligned} p(\mu | x_1, \dots, x_n) &= \frac{p(\mu) p(x_1, \dots, x_n | \mu)}{\int_0^1 p(\mu) p(x_1, \dots, x_n | \mu) d\mu} \propto p(\mu) p(x_1, \dots, x_n | \mu) \propto p(\mu) p(\bar{x} | \mu) \\ &\propto \exp\left\{-\frac{1}{2\tau^2} (\mu - \mu_0)^2\right\} \exp\left\{-\frac{n}{2\sigma^2} (\bar{x} - \mu)^2\right\} \\ &\propto \exp\left\{-\left[\frac{1}{2\tau^2} (\mu - \mu_0)^2 + \frac{n}{2\sigma^2} (\bar{x} - \mu)^2\right]\right\}. \quad (1) \end{aligned}$$

Usando o lema (continuação)

Definindo $Q(\mu) = \frac{1}{2\tau^2} (\mu - \mu_0)^2 + \frac{n}{2\sigma^2} (\bar{x} - \mu)^2$ e usando o Lema 1, segue que a distribuição a posteriori é Normal com média e variâncias dadas por

$$\mu^* = \mathbb{E}(\mu \mid x_1, \dots, x_n) = -\frac{Q'(0)}{Q''(0)} = \frac{\frac{1}{\tau^2} \mu_0 + \frac{n}{\sigma^2} \bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \quad (2)$$

e

$$\tau^{*2} = \text{Var}(\mu \mid x_1, \dots, x_n) = \frac{1}{Q''(0)} = \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}. \quad (3)$$

Interpretação pelas precisões

$$\mu^* = \mathbb{E}(\mu \mid x_1, \dots, x_n) = -\frac{Q'(0)}{Q''(0)} = \frac{\frac{1}{\tau^2} \mu_0 + \frac{n}{\sigma^2} \bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \quad (2)$$

$$\tau^{*2} = \text{Var}(\mu \mid x_1, \dots, x_n) = \frac{1}{Q''(0)} = \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}. \quad (3)$$

Algumas vezes na literatura Bayesiana a variância da distribuição a priori é parametrizada pelo recíproco $\phi = \tau^{-2}$, denominada de *precisão*. De forma semelhante, a *precisão* da distribuição amostral de \bar{x} é $[\text{Var}(\bar{x} \mid \mu)]^{-1} = n/\sigma^2$. Com essa nova terminologia, a equação (3) diz simplesmente que “a *precisão a posteriori* $[\text{Var}(\mu \mid x_1, \dots, x_n)]^{-1}$ é igual a *precisão a priori* τ^{-2} mais a *precisão amostral* n/σ^2 ”. De forma semelhante, a equação (2) diz que “a *média a posteriori* é uma *média ponderada da média a priori* μ_0 e da *média amostral* \bar{x} com pesos proporcionais as respectivas *precisões*”. Por exemplo, quanto maior for o tamanho amostral n , se τ^2 e σ^2 , mais perto de \bar{x} vai estar a média a posteriori.

As balanças incertas

Exemplo 1. Um objeto foi pesado $n = 10$ vezes numa balança retornando média $\bar{x} = 3.53\text{g}$. Segundo o fabricante da balança, para esse tipo de objetos a balança é muito precisa e o desvio padrão das pesadas deve ser da ordem de $\sigma = 0.2\text{g}$.

Uma outra balança, menos precisa, também estava disponível e nela o objeto foi pesado $m = 50$ vezes retornando média e desvio padrão iguais a $\bar{y} = 3.25$ e $s_y = 0.5\text{g}$.

Construa um modelo para analisar esses dados e com base nele obtenha um intervalo que contem μ com probabilidade a posteriori igual a 95%.

As balanças (continuação)

Podemos usar a informação da balança menos precisa para justificar uma distribuição a priori $\mu \sim \text{Normal}(3.25, 0.5^2)$ (formalmente, a distribuição a posteriori resultante de usar uma priori não informativa com os dados da balança menos precisa seria t de Student com 49 graus de liberdade—veja as Seções 1.2.1 e 1.2.2 abaixo, mas como n é grande, a distribuição Normal é uma boa aproximação). Logo, podemos tomar $\mu_0 = \bar{y} = 3.25$ e $\tau^2 = s_y^2 = 0.5^2$. Usando o valor de $\bar{x} = 3.53$ usamos as equações (2) e (3) para calcular


$$\mu^* = \frac{\frac{1}{0.5^2} (3.25) + \frac{10}{0.2^2} 3.53}{\frac{1}{0.5^2} + \frac{10}{0.2^2}} \doteq 3.5256 \quad \tau^{*2} = \frac{1}{\frac{1}{0.5^2} + \frac{10}{0.2^2}} \doteq (0.0627)^2.$$

Assim a posteriori, $\mu \mid x_1, \dots, x_n \sim \text{Normal}(3.5256, 0.0627^2)$. O intervalo desejado é então

$$\mu^* \pm z_{\alpha/2} \tau^* \doteq 3.5256 \pm (1.96) (0.0627) \doteq (3.4026; 3.6486).$$

As balanças (conclusão)

$$n/\sigma^2 = 250 \quad 1/\tau^2 = 4$$



Prioris "não informativas"

Na situação descrita nesta Seção tem duas formas de pensar numa distribuição a priori *pouco informativa*. Uma, é fazer a variância τ^2 da distribuição a priori muito grande. Em particular, quando $\tau^2 \rightarrow \infty$, tomando limites nas equações (2) e (3), vemos que a distribuição a posteriori tende a uma Normal com média \bar{x} e variância σ^2/n , que depende somente da verossimilhança (veja que o valor de μ_0 também some uma vez que fazemos $\tau^2 \rightarrow \infty$). Outra forma de proceder é pensar numa “distribuição uniforme” para μ , algo assim como especificar em (1) $p(\mu)$ igual a uma constante $c > 0$ (como a constante c no numerador cancela com a do denominador, usualmente escreve-se $p(\mu) \propto 1$). Porém, a distribuição uniforme não está definida num intervalo infinito como a reta real ou, em outras palavras, não é possível normalizar a densidade para que integre um pois $\int_{-\infty}^{\infty} c d\mu = \infty$ (lembre da discussão sobre $w(\theta)$ e $w^*(\theta) = w(\theta) / \int w(\theta) d\theta$ na Seção ??), de forma que essa possibilidade está, ao menos formalmente, fora do paradigma Bayesiano.

Prioris "não informativas" (continuação)

Ainda, é possível pôr $p(\mu) \propto 1$ na equação (1) e, formalmente, fazer as mesmas contas que faríamos com uma distribuição a priori “*verdadeira*”. Se o fizermos, chegaríamos a que

$$p(\mu | x_1, \dots, x_n) \propto p(x_1, \dots, x_n | \theta) \propto p(\bar{x} | \theta) \propto \exp\left\{-\frac{n}{2\sigma^2}(\mu - \bar{x})^2\right\},$$

o que implica que $\mu | x_1, \dots, x_n \sim \text{Normal}(\bar{x}, \sigma^2/n)$, que é o mesmo resultado ao qual chegamos fazendo $\tau^2 \rightarrow \infty$.

Prioris "não informativas" (continuação)

Na literatura, quando se usa uma “distribuição a priori” que, como no caso anterior, tem integral infinita, fala-se de uma “*distribuição a priori imprópria*”. As aspas foram usadas acima pois, pelo menos na opinião do autor destas notas, distribuições a priori impróprias não são distribuições a priori. De qualquer forma, distribuições impróprias ou com variância infinita podem ser apropriadas em situações nas quais deseja-se usar uma distribuição a priori relativamente “achatada” (*flat*) na região onde a verossimilhança é significativamente diferente de zero. No caso particular desta seção, a verossimilhança $p(x_1, \dots, x_n | \mu) \propto \exp\{-n(\mu - \bar{x})^2\}$ comporta-se semelhante a uma densidade Normal e decresce muito rapidamente a zero quando μ se afasta de \bar{x} . Na maioria das situações práticas, o valor da densidade a priori $p(\mu)$ para valores de μ que distam de \bar{x} (digamos) mais do que 3 ou 4 vezes o desvio padrão σ/\sqrt{n} é irrelevante. Nessas situações uma distribuição a priori imprópria $p(\mu) \propto 1$ pode ser uma aproximação conveniente e mais fácil de especificar que uma distribuição própria.

Prioris "não informativas" (conclusão)

Seja fazendo $\tau^2 \rightarrow \infty$ ou usando $p(\mu) \propto 1$, a seguinte observação merece ser feita. Uma vez que chegamos no resultado $\mu | x_1, \dots, x_n \sim \text{Normal}(\bar{x}, \sigma^2/n)$, se denotarmos por $z_{\alpha/2}$ o quantil $(1 - \alpha/2)$ da distribuição Normal Padrão, podemos escrever que

$$\mathbb{P} \left(\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \mid x_1, \dots, x_n \right) = 1 - \alpha. \quad (4)$$

Em comparação, na estatística clássica, quando calcula-se o intervalo de confiança usual nesta situação, tem-se que

$$\mathbb{P}_{\mu} \left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right) = 1 - \alpha. \quad (5)$$

Note a diferença na interpretação dessas duas afirmações. Em (4), a variável aleatória é μ , enquanto \bar{x} está fixa no valor que foi efetivamente observado. Em (5), a variável aleatória é \bar{X} , enquanto μ está fixa num valor desconhecido.

Distribuições Preditivas

$X_1, \dots, X_n, X_{n+1}, \dots, X_{n+m} \mid \mu \stackrel{iid}{\sim} \text{Normal}(\mu, \sigma^2)$ com a distribuição a priori $\mu \sim \text{Normal}(\mu_0, \tau^2)$. Com base na observação de $\bar{x}_{1:n} = n^{-1} \sum_{i=1}^n x_i$ desejamos prever $\bar{X}_{(n+1):(n+m)} = m^{-1} \sum_{i=n+1}^{m+n} X_i$ ou, em outras palavras, procuramos a distribuição condicional de $\bar{X}_{(n+1):(n+m)}$ dado $\bar{x}_{1:n}$. (se for desejado somente a distribuição preditiva de uma única observação futura X_{n+1} , tome $m = 1$ nos resultados a seguir).

Distribuições Preditivas (continuação)

Essa distribuição pode ser achada diretamente da distribuição conjunta de $(\theta, \bar{X}_{1:n}, \bar{X}_{(n+1):(n+m)})$ integrando primeiro com respeito a θ e depois usando a definição de densidade condicional. Neste caso, porém, é mais fácil proceder da seguinte forma. Primeiro, veja que a distribuição conjunta do vetor $(X_1, \dots, X_{n+m}, \theta)$ é Normal $(n + m + 1)$ -variada. Logo, todas as distribuições marginais e condicionais também serão Normais multivariadas. Em particular, $X_{n+1}, \dots, X_{n+m} \mid \bar{x}_{1:n}$ segue uma distribuição Normal m -variada e, sendo $\bar{X}_{(n+1):(n+m)}$ uma combinação linear de X_{n+1}, \dots, X_{n+m} , concluímos que a distribuição preditiva de $\bar{X}_{(n+1):(n+m)}$ dado $\bar{x}_{1:n}$ deve ser Normal univariada. Assim, é suficiente achar os dois primeiros momentos da distribuição preditiva, o que pode ser feito facilmente com as propriedades (??)–(??). Isto é, lembrando que os dois primeiros momentos da distribuição a posteriori de $\mu \mid \bar{x}_{1:n}$ são dados pelas equações (2)–(3),

Distribuições Preditivas (continuação)

$$\begin{aligned}\mathbb{E}(\bar{X}_{(n+1):(n+m)} \mid \bar{x}_{1:n}) &= \mathbb{E}_{\mu \mid \bar{x}_{1:n}} \mathbb{E}(\bar{X}_{(n+1):(n+m)} \mid \bar{x}_{1:n}, \mu) \\ &= \mathbb{E}_{\mu \mid \bar{x}_{1:n}} \mathbb{E}(\bar{X}_{(n+1):(n+m)} \mid \mu) = \mathbb{E}_{\mu \mid \bar{x}_{1:n}}(\mu) = \frac{\frac{1}{\tau^2} \mu_0 + \frac{n}{\sigma^2} \bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \mu^*\end{aligned}$$
$$\begin{aligned}\text{Var}(\bar{X}_{(n+1):(n+m)} \mid \bar{x}_{1:n}) &= \mathbb{E}_{\mu \mid \bar{x}_{1:n}} \text{Var}(\bar{X}_{(n+1):(n+m)} \mid \bar{x}_{1:n}, \mu) + \text{Var}_{\mu \mid \bar{x}_{1:n}} \mathbb{E}(\bar{X}_{(n+1):(n+m)} \mid \bar{x}_{1:n}, \mu) \\ &= \mathbb{E}_{\mu \mid \bar{x}_{1:n}} \text{Var}(\bar{X}_{(n+1):(n+m)} \mid \mu) + \text{Var}_{\mu \mid \bar{x}_{1:n}} \mathbb{E}(\bar{X}_{(n+1):(n+m)} \mid \mu) \\ &= \mathbb{E}_{\mu \mid \bar{x}_{1:n}} \left(\frac{\sigma^2}{m} \right) + \text{Var}_{\mu \mid \bar{x}_{1:n}}(\mu) = \frac{\sigma^2}{m} + \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \frac{\sigma^2}{m} + \tau^{*2}.\end{aligned}$$

Veja que esta última variância reflete duas fontes de incerteza com respeito a $\bar{X}_{(n+1):(n+m)}$: o primeiro termo σ^2/m tem a ver com a variabilidade inerente de $\bar{X}_{(n+1):(n+m)}$, enquanto o segundo termo τ^{*2} reflete a incerteza com respeito à média μ .